



Ejercicio Formativo 3 Capítulo 1

Aspectos generales

- **Objetivos:** aplicar los contenidos de análisis de datos tabulares.
- **Formato de entrega:** archivo `E3.ipynb`, ubicado en la carpeta **C1** del repositorio.
- **ULTRA IMPORTANTE:** todas las celdas utilizadas deben estar ejecutadas al momento de entregar el ejercicio, de modo que las salidas generadas sean visibles. En caso de no cumplir esto, su entrega no será considerada como validación del ticket de participación.

Descripción del problema

Considere el conjunto de datos almacenado en el archivo `E3_data.csv`, que contiene datos obtenidos a lo largo de los años sobre los niveles de ozono (O_3) y material particulado de 2.5 micrómetros ($PM_{2.5}$). Además, cada registro puede incluir una categoría de riesgo ambiental entre las disponibles en los datos: nulo, bajo, medio, alto y extremo. En base a esta información, complete las misiones indicadas a continuación.

Misión 0: aspectos básicos

Para cumplir las misiones de este taller, es fundamental explorar inicialmente el contenido del archivo y familiarizarse con el formato en que está almacenada la información. Para eso, utilice los comandos `describe` y `head` de `pandas`.

Misión 1: imputación de información faltante

Tanto para O_3 como para $PM_{2.5}$, el conjunto contiene datos incompletos para algunos días, generados por motivos desconocidos. Cree dos nuevos `DataFrame` a partir de los datos originales. En el primero, complete

los valores faltantes de O_3 y $PM_{2.5}$ utilizando la media de la columna correspondiente. En el segundo, elimine todas las filas que tengan un valor faltante en al menos una de estas dos columnas.

Misión 2: descripción y comparación

A continuación, para ambos **DataFrame** generados en la misión anterior y de manera independiente, imprima en una tabla ordenada los siguientes indicadores para O_3 y $PM_{2.5}$: media, desviación estándar, máximo, mínimo y curtosis. Además, agregue a esta tabla la correlación entre O_3 y $PM_{2.5}$.

Durante la sesión se informará una variante individual que determinará un mes y un contaminante. Para ambos **DataFrame**, calcule la media del contaminante asignado considerando únicamente los registros del mes indicado. Mantenga visibles ambos resultados, pues serán requeridos en el ticket de participación.

Misión 3: visualización

Para ambos **DataFrame** obtenidos en la primera misión y de manera independiente, genere las siguientes visualizaciones:

- Histograma de $PM_{2.5}$
- Boxplot de O_3 por mes
- Evolución promedio de O_3 y $PM_{2.5}$ por año

Misión 4: categorización

En base a todos los análisis realizados anteriormente, proponga e implemente en Python un esquema para asignar un nivel de riesgo medioambiental a cada registro que no tiene esta información. Complete esto para ambos **DataFrame** de manera independiente. Comente y analice los resultados.

Misión 5: análisis temporal avanzado

Identifique patrones estacionales en los datos, utilizando el archivo `E3_data.csv` para crear una nueva columna que indique la estación del año (primavera, verano, otoño, invierno) para cada registro basado en la fecha. Calcule la media de O_3 y $PM_{2.5}$ para cada estación y cada año y, finalmente, genere una visualización que muestre la evolución de las medias estacionales de O_3 y $PM_{2.5}$ a lo largo del tiempo.

Misión 6: detección de anomalías

Identifique registros atípicos que puedan indicar problemas en la recolección de datos o eventos excepcionales. Para esto, implemente un método basado en el rango intercuartílico (IQR) para identificar valores atípicos en las columnas de O_3 y $PM_{2.5}$. Cree un nuevo **DataFrame** que contenga únicamente los registros considerados atípicos y analice si hay alguna relación temporal o estacional en ellos.

Misión 7: transformación y enriquecimiento de datos

Realice manipulaciones avanzadas de datos para crear nuevas variables y enriquecer el conjunto de datos, en base a los siguientes pasos:

- Cree una nueva columna que calcule la razón (*ratio*) entre los niveles de O_3 y $PM_{2.5}$
- Implemente un algoritmo para detectar y marcar días consecutivos con niveles extremos de O_3 o $PM_{2.5}$, por encima del percentil 95
- Genere una nueva columna que clasifique cada registro según el día de la semana y determine si es fin de semana o día laboral
- Cree una tabla dinámica (*pivot table*) que muestre la media de O_3 y $PM_{2.5}$ por mes y por nivel de riesgo ambiental
- Utilice **groupby** y **rolling** para calcular la media móvil de siete días para O_3 y $PM_{2.5}$, y añada estas columnas al conjunto de datos
- Analice y comente cómo estas transformaciones enriquecen la comprensión del conjunto de datos