



Ejercicio Formativo 4 Capítulo 1

Aspectos generales

- **Objetivos:** aplicar los contenidos de análisis de datos tabulares con Pandas.
- **ULTRA IMPORTANTE:** todas las celdas utilizadas deben estar ejecutadas al momento de entregar el ejercicio, de modo que las salidas generadas sean visibles.

Descripción del problema

Netflix es un conocido servicio de *streaming* con un amplio catálogo de películas y series. La empresa ha organizado el concurso “Director/a por un día” y usted ha obtenido el ticket ganador. Como parte del desafío, deberá analizar datos públicos del catálogo para identificar tendencias que puedan orientar las características de una nueva película.

El análisis deberá considerar que los datos disponibles describen el catálogo, pero no contienen información directa sobre audiencia o éxito comercial. Por lo tanto, las conclusiones deberán interpretarse dentro de esas limitaciones.

La base de datos

Los datos se encuentran disponibles en el archivo `E4_data.csv`. Cada registro corresponde a una producción del catálogo y contiene las siguientes columnas:

show_id	Identificador único de la producción
type	Indica si corresponde a una película o serie
title	Título de la producción
director	Nombre de quien o quienes dirigieron la producción
country	País o países asociados a la producción
date_added	Fecha de incorporación al catálogo de Netflix
release_year	Año de estreno
rating	Clasificación por edades
duration	Duración informada de la producción
listed_in	Géneros o categorías asociados a la producción

Misiones

Misión 1: diagnóstico de los datos

Realice un diagnóstico que le permita comprender la estructura y calidad del conjunto de datos antes de modificarlo. El diagnóstico debe identificar, al menos, la información incompleta, posibles registros duplicados, formatos que requieran transformación y valores que puedan considerarse anómalos.

Seleccione resúmenes y visualizaciones adecuadas para respaldar sus observaciones. No es necesario corregir todavía los problemas detectados, pero sí explicar cuáles podrían afectar los análisis solicitados posteriormente y por qué.

Misión 2: diseño de la solución

Antes de preparar los datos y responder las siguientes misiones, describa a alto nivel, preferentemente con un diagrama, la solución que propone desarrollar. Esta descripción debe permitir comprender la lógica completa del trabajo sin incluir código ni limitarse a enumerar funciones de Pandas.

Incluya:

- Los principales problemas identificados en los datos
- La secuencia general de transformaciones que propone realizar
- Los criterios que utilizará para tratar duplicados e información faltante
- La forma en que representará los géneros de una producción

- Las comprobaciones que utilizará para validar los datos preparados
- La información que necesitará obtener para responder las consultas finales

La estrategia podrá modificarse durante el desarrollo. Si esto ocurre, registre los cambios realizados y explique brevemente qué observación motivó cada uno.

Misión 3: preparación de los datos

Implemente una versión preparada del conjunto de datos a partir del diagnóstico y la estrategia anterior.

Para cada problema de duplicación o información faltante, deberá adoptar una decisión coherente con el uso posterior de la variable. Según el caso, podrá imputar información, eliminar registros, conservar valores faltantes o excluir una columna de determinados análisis. Justifique los criterios utilizados y analice las consecuencias que tendría eliminar filas completas.

Al finalizar, compare los datos originales con los datos preparados y compruebe que las transformaciones no hayan eliminado o modificado información de manera no intencional.

Misión 4: representación de géneros

A partir de la información contenida en `listed_in`, construya una representación que permita determinar si cada producción pertenece a las siguientes categorías:

- Action & Adventure
- Comedy
- Drama
- Horror
- Mystery
- Sci-Fi & Fantasy
- Thrillers
- Independent
- Children & Family

Defina y construya una representación que permita utilizar estas categorías en los análisis posteriores, considerando que una producción puede pertenecer a más de una de ellas. Justifique la estructura elegida y explique cómo conservará la relación entre las categorías identificadas y cada `show_id`.

Establezca también los criterios necesarios para reconocer categorías relacionadas, variantes de escritura, sinónimos y plurales. Integre o vincule el resultado con el conjunto de datos preparado de la forma que considere más adecuada y compruebe que la transformación no haya agregado, eliminado o duplicado producciones de manera incorrecta.

Misión 5: consultas

Utilice los datos preparados para responder las siguientes consultas. Para cada una, explique las decisiones necesarias para traducir la pregunta en un análisis de datos, explicité sus supuestos y respalde la respuesta con resultados numéricos y visualizaciones cuando corresponda.

- a) ¿Cuál es el género con mayor presencia en los últimos cinco años disponibles en los datos? ¿En qué década se estrenó la mayor cantidad de películas de ese género? ¿Qué país ha producido más películas de este tipo?
- b) En promedio, ¿cuánto demora una producción en incorporarse al catálogo de Netflix después de su estreno? Para producciones anteriores a la creación del catálogo de *streaming*, utilice 2008 como la primera fecha posible de incorporación.
- c) ¿Cómo ha cambiado en el tiempo la distribución de las clasificaciones por edades de las producciones pertenecientes a la categoría **Horror**? Construya una visualización adecuada e interprete los principales cambios observados.

Finalmente, sintetice qué resultados podrían orientar las características de la película propuesta y qué limitaciones impiden interpretar estas tendencias como una garantía de éxito.