

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2115 - Programación como herramienta para la ingeniería

Exploración, limpieza y análisis de datos con Pandas

Profesor: Hans Löbel

En esta clase, aprovecharemos no solo de usar herramientas, sino que también practicar una forma ordenada de responder preguntas con datos

- Los datos tabulares son los más tradicionales, abundantes e intuitivos, lo que los convierte en un excelente punto de inicio.
- Desde un punto de vista práctico, realizaremos las siguientes tareas:
 - Carga y combinación de datos de distintas fuentes
 - Limpieza, corrección y transformación
 - Exploración y descripción de distintas dimensiones de los datos
 - Análisis estadístico



Como problema guía para la clase, estudiaremos la siguiente pregunta:

¿Cómo se distribuye y se comporta la demanda de buses en una ciudad?

¿Qué conclusiones parecen razonables dado el estado de los datos?

Como insumo para el estudio, asumamos que tenemos un archivo `.csv` con registros diarios de uso de buses en distintas comunas de Santiago

¿Cómo conviene enfrentar un problema con datos?

- Entender qué pregunta queremos responder.
- Revisar rápidamente qué contienen los datos.
- Detectar problemas antes de concluir algo.
- Resumir y comparar con criterio.
- Sacar conclusiones a partir de los resultados.
- Dejar bases útiles para reutilizar después.



Para el análisis de este archivo utilizaremos **Pandas**

- Cargar y revisar datos tabulares.
- Limpiar y transformar.
- Resumir y comparar.
- Preparar resultados para análisis y visualización.



Lo mínimo que necesitamos: DataFrame y Series

- Un DataFrame es una tabla.
- Cada columna es una Series.
- Esto importa porque a veces trabajamos con la tabla completa y otras con una variable específica.

```
1 import pandas as pd
```

```
1 df = pd.read_csv("buses_santiago.csv")  
2 df.shape
```

```
(5760, 8)
```

```
1 df.head()
```

	fecha	linea_bus	comuna_origen	comuna_destino	validaciones	clima	dia_semana	eventos_especiales
0	2024-05-16	L06	Las Condes	Pudahuel	18	Lluvia	Jueves	0
1	2024-05-23	L06	Independencia	Pudahuel	19	Soleado	Jueves	0
2	2024-04-23	L07	Ñuñoa	Las Condes	17	Soleado	Martes	0
3	2024-05-21	L02	Providencia	Independencia	19	Nublado	Martes	0
4	2024-05-26	L02	Maipú	Estación Central	10	Nublado	Domingo	0

Lo mínimo que necesitamos: DataFrame y Series

- Un DataFrame es una tabla.
- Cada columna es una Series.
- Esto importa porque a veces trabajamos con la tabla completa y otras con una variable específica.

```
1 df["validaciones"]
```

validaciones

0	18
1	19
2	17
3	19
4	10
...	...
5755	26
5756	14
5757	9
5758	18
5759	10

5760 rows × 1 columns

dtype: int64

Ahora que conocemos los aspectos generales sobre el formato y contenido de los datos, ¿cómo podemos avanzar en el problema?

- Necesitamos una visión general de los datos.
- Conviene partir por resúmenes simples y descriptivos.
- El objetivo es detectar señales útiles y posibles problemas.
- Lo importante es que este primer análisis guíe los siguientes pasos.


```
1 df.describe()
```

	validaciones	eventos_especiales
count	5444.000000	5760.000000
mean	17.311352	0.050000
std	15.350443	0.217964
min	4.000000	0.000000
25%	12.000000	0.000000
50%	15.500000	0.000000
75%	19.000000	0.000000
max	199.000000	1.000000

```
1 df["clima"].value_counts()
```

	count
clima	
Nublado	2147
Soleado	1862
Lluvia	1587

```
1 df["comuna_origen"].value_counts()
```

	count
comuna_origen	
Las Condes	480
Independencia	480
Ñuñoa	480
Providencia	480
Maipú	480
Recoleta	480
Santiago	480
Estación Central	480
La Florida	480
Pudahuel	480
Puente Alto	480
San Miguel	480

¿Qué señales de alerta o de interés aparecen al mirar estos resúmenes?

Si el análisis inicial nos genera ciertas dudas sobre la validez de los datos, es necesario revisarlos en más detalle y corregirlos

```
1 df.isna().sum()
```

	0
fecha	0
linea_bus	0
comuna_origen	0
comuna_destino	0
validaciones	316
clima	164
dia_semana	0
eventos_especiales	0

```
1 df["validaciones"] = df["validaciones"].fillna(df["validaciones"].mean())  
2 df.describe()
```


	validaciones	eventos_especiales
count	5760.000000	5760.000000
mean	17.311352	0.050000
std	14.923357	0.217964
min	4.000000	0.000000
25%	12.000000	0.000000
50%	16.000000	0.000000
75%	19.000000	0.000000
max	199.000000	1.000000



Aún restan situaciones que corregir

- ¿Cómo podemos corregir los *outliers* de las validaciones?
- ¿Basta con eliminarlos?
- ¿Son realmente *outliers*?
- Un valor extremo no siempre es un error

```
1 df.boxplot(column="validaciones");
```



Aún restan situaciones que corregir

- ¿Cuál era el problema con el conteo de la variable **clima**?
- ¿Por qué es distinta **clima** de **validaciones**?
- En variables categóricas las estrategias cambian.
- A veces basta con la moda.
- Otras veces conviene usar contexto adicional.
- La decisión depende de cuánto podamos justificarla.

```
1 df["clima"].value_counts()
```

count	
clima	
Nublado	2147
Soleado	1862
Lluvia	1587

Revisitemos parte del análisis exploratorio inicial

```
1 df["comuna_origen"].value_counts()
```

	count
comuna_origen	
Las Condes	480
Independencia	480
Ñuñoa	480
Providencia	480
Maipú	480
Recoleta	480
Santiago	480
Estación Central	480
La Florida	480
Pudahuel	480
Puente Alto	480
San Miguel	480

```
1 df["comuna_destino"].value_counts()
```

	count
comuna_destino	
Estación Central	534
Maipú	492
Recoleta	488
Las Condes	488
La Florida	482
Puente Alto	481
Providencia	480
San Miguel	479
Independencia	476
Pudahuel	466
Ñuñoa	452
Santiago	442

Si la cobertura parece sesgada, ¿qué información externa nos ayudaría a interpretar mejor los datos?

No siempre basta con los datos originales, a veces hay que contextualizarlos

```
1 poblacion = pd.read_csv("poblacion_comunas.csv")
2 poblacion.head()
```

	comuna_origen	poblacion
0	Santiago	404495
1	Providencia	151000
2	Las Condes	300000
3	Ñuñoa	240000
4	La Florida	366000

```
1 df = pd.merge(df, poblacion, on="comuna_origen", how="left")
2 df.head()
```

	fecha	linea_bus	comuna_origen	comuna_destino	validaciones	clima	dia_semana	eventos_especiales	poblacion
0	2024-05-16	L06	Las Condes	Pudahuel	18.0	Lluvia	Jueves	0	300000
1	2024-05-23	L06	Independencia	Pudahuel	19.0	Soleado	Jueves	0	150000
2	2024-04-23	L07	Ñuñoa	Las Condes	17.0	Soleado	Martes	0	240000
3	2024-05-21	L02	Providencia	Independencia	19.0	Nublado	Martes	0	151000
4	2024-05-26	L02	Maipú	Estación Central	10.0	Nublado	Domingo	0	520000

Centrémonos ahora en el estudio de la demanda

Enfoquemos el análisis inicial en ciertos subconjuntos de datos y además en derivar nuevas variables que capturen información relevante. Algunas preguntas relevantes son las siguientes:

- ¿Qué criterios son útiles para filtrar datos? (ej. analizar solo horas punta, o excluir líneas con pocos registros).
- ¿Qué nuevas variables pueden enriquecer el análisis sin tener que recurrir a datos externos? (ej. variable binaria de fin de semana, discretización de población en tramos).

```
1 df[["fecha", "linea_bus", "validaciones"]]
```

	fecha	linea_bus	validaciones
0	2024-05-16	L06	18.0
1	2024-05-23	L06	19.0
2	2024-04-23	L07	17.0
3	2024-05-21	L02	19.0
4	2024-05-26	L02	10.0
...	...	...	...
5755	2024-05-10	L03	26.0
5756	2024-05-25	L01	14.0
5757	2024-05-25	L04	9.0
5758	2024-05-27	L02	18.0
5759	2024-04-09	L08	10.0

5760 rows × 3 columns



```
1 df[df["dia_semana"].isin(["Lunes", "Martes", "Miércoles", "Jueves", "Viernes"])]
```

	fecha	linea_bus	comuna_origen	comuna_destino	validaciones	clima	dia_semana	eventos_especiales	poblacion
0	2024-05-16	L06	Las Condes	Pudahuel	18.0	Lluvia	Jueves	0	300000
1	2024-05-23	L06	Independencia	Pudahuel	19.0	Soleado	Jueves	0	150000
2	2024-04-23	L07	Ñuñoa	Las Condes	17.0	Soleado	Martes	0	240000
3	2024-05-21	L02	Providencia	Independencia	19.0	Nublado	Martes	0	151000
5	2024-04-12	L04	Recoleta	Independencia	11.0	Lluvia	Viernes	0	180000
...	...	...	...	...	...	...	...	...	...
5753	2024-05-30	L06	San Miguel	Providencia	15.0	Soleado	Jueves	0	120000
5754	2024-05-03	L02	Independencia	Puente Alto	11.0	Lluvia	Viernes	0	150000
5755	2024-05-10	L03	La Florida	Las Condes	26.0	Soleado	Viernes	0	366000
5758	2024-05-27	L02	Las Condes	Puente Alto	18.0	Soleado	Lunes	0	300000
5759	2024-04-09	L08	Independencia	Ñuñoa	10.0	Lluvia	Martes	0	150000

4224 rows × 9 columns

```
1 df["fin_de_semana"] = df["dia_semana"].isin(["Sábado", "Domingo"])
2 df["densidad_validaciones"] = df["validaciones"] / df["poblacion"]
```


Agregación es otro tipo de análisis útil que podemos hacer

Busquemos también entender tendencias globales. Por ejemplo, para entender cómo cambia la demanda de buses según el día de la semana y la línea de bus, deberíamos realizar lo siguiente:

- Definir qué grupos queremos comparar.
- Elegir el nivel de agregación adecuado.
- Seleccionar una métrica que represente bien los datos.

¿Qué patrón podemos apreciar al mirar los promedios?

```
1 df.groupby("dia_semana")["validaciones"].mean()
```

validaciones	
dia_semana	
Domingo	10.056175
Jueves	19.468097
Lunes	19.430263
Martes	19.509064
Miércoles	19.949010
Sábado	14.038438
Viernes	17.589538

dtype: float64

¿Qué limitaciones tiene mirar solo los promedios?

```
1 df.groupby(["linea_bus", "dia_semana"])["validaciones"].agg(["mean", "median", "std"])
```

		mean	median	std
linea_bus	dia_semana			
L01	Domingo	10.168536	10.000000	3.078729
	Jueves	19.167718	17.000000	19.981879
	Lunes	16.958859	16.000000	4.062942
	Martes	19.150420	16.000000	17.407154
	Miércoles	19.807828	17.000000	20.221883
	Sábado	11.724550	11.000000	2.957183
	Viernes	14.887973	14.000000	3.575008
L02	Domingo	10.876869	10.000000	2.922466
	Jueves	19.683353	17.655676	10.500659
	Lunes	20.062983	18.000000	15.166870
	Martes	21.141161	19.000000	17.254086
	Miércoles	21.542192	20.000000	17.048387
	Sábado	14.353480	12.500000	13.339652
	Viernes	18.794910	17.000000	14.406436
L03	Domingo	12.207646	11.000000	9.958066
	Jueves	23.297958	21.000000	17.842755

Otra forma de resumir información: tablas dinámicas

Típicamente, buscaremos cruzar múltiples dimensiones (ej. clima × día de semana × comuna) para buscar patrones relevantes.

Para esto, lo mejor es utilizar tablas dinámicas:

- Son útiles para cruzar varias dimensiones.
- Facilitan la comparación visual entre grupos.
- Sirven especialmente cuando queremos preparar una visualización.

```
1 pd.pivot_table(df, values="validaciones", index="clima", columns="dia_semana", aggfunc="mean")
```

dia_semana	Domingo	Jueves	Lunes	Martes	Miércoles	Sábado	Viernes
clima							
Lluvia	9.752944	15.517679	20.268108	18.161643	NaN	12.641847	16.437221
Nublado	9.854344	18.720331	19.127955	19.915195	18.971142	13.458199	NaN
Soleado	10.770664	20.207633	20.326312	21.214691	21.507261	17.178143	21.236303



Cómo sigue la sesión

- 3 ejercicios formativos disponibles (E2, E3 y E4), primeros 2 son el foco para el avance durante la sesión.
- El primer ejercicio (E2) busca afianzar lo más básico.
- El segundo (E3) les permitirá practicar varias técnicas en conjunto.
- El tercero (E4) es más desafiante y tiene como objetivo su desarrollo durante la semana. **Especial atención merece la Misión 2.**
- Instrucciones para el ticket de participación de indicarán al inicio del segundo módulo.



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2115 - Programación como herramienta para la ingeniería

Exploración, limpieza y análisis de datos con Pandas

Profesor: Hans Löbel