



## Ejercicio Formativo 1 Capítulo 2

### Aspectos generales

- **Objetivos:** familiarizarse con los elementos fundamentales de los modelos predictivos de aprendizaje supervisado.
- **ULTRA IMPORTANTE:** todas las celdas utilizadas deben estar ejecutadas al momento de desarrollar el ejercicio, de modo que las salidas generadas sean visibles.

### Descripción del problema

Debido a los problemas climáticos presentes en la tierra, muchos investigadores están sumamente preocupados por las reducciones en el hábitat de pingüinos. Para poder ayudarlos, es importante identificar las distintas especies y así brindarles la ayuda específica. Para esto, se ha hecho pública una base de datos que almacena características de pingüinos de diferentes razas.

### Datos

La base de datos se encuentra disponible en el sitio del curso, en el archivo `E1_datos.csv`. Esta contiene información de pingüinos usando las siguientes variables:

1. **species:** etiqueta de los datos correspondiente a la especie a la que pertenece el pingüino.
2. **island:** isla de procedencia del pingüino.
3. **culmen\_length\_mm:** largo de la parte superior del pico del pingüino.
4. **culmen\_depth\_mm:** profundidad de la parte superior del pico del pingüino.

5. **flipper\_length\_mm**: largo de la aleta del pingüino.
6. **body\_mass\_g**: masa del cuerpo del pingüino.
7. **sex**: sexo del pingüino.

## Misiones

### Misión 0: completando información

Abra el archivo y complete la información numérica faltante utilizando el valor promedio de cada columna. A continuación, descarte los registros para los cuales hay variables categóricas con valores faltantes.

### Misión 1: preparación de los datos

Prepare los datos para su uso posterior en los modelos predictivos. Para esto, siga los pasos descritos en el material del curso para evitar *data leakage*. Específicamente, debe realizar los siguientes pasos en orden:

1. Codificación numérica de variables categóricas.
2. Separación en conjuntos de entrenamiento y test.
3. Escalamiento de variables numéricas.

### Misión 2: predicción de la especie

Encuentre el mejor modelo para predecir la especie de un pingüino dadas sus características. En particular, deberá evaluar dos posibles estrategias para construir modelos:

- Predicción tradicional: entrenamiento de modelos para predecir directamente la raza de cada pingüino.
- Predicción jerárquica: entrenamiento de dos modelos para predecir la raza del pingüino. El primero debe discriminar entre 1 raza y las otras 2, mientras que el segundo debe discriminar entre las dos que formaron el mismo grupo para el modelo anterior. Qué raza usar para cada grupo y modelo es una decisión que debe tomar ud.

En todos los esquemas, puede elegir la familia de modelos que desee. Reporte siempre el rendimiento de los modelos en un conjunto independiente de test.