



IIC2115 – Programación como Herramienta para la Ingeniería (II/2026)

Ejercicio Formativo 2 Capítulo 2

Aspectos generales

- **Objetivos:** practicar los contenidos de modelos predictivos de aprendizaje supervisado.
- **ULTRA IMPORTANTE:** todas las celdas utilizadas deben estar ejecutadas al momento de desarrollar el ejercicio, de modo que las salidas generadas sean visibles.

Descripción del problema

Considere el conjunto de datos almacenado en el archivo `E2.datos.csv`, que contiene datos obtenidos a lo largo de los años sobre los niveles de Ozono (O_3) y material particulado de 2.5 micrómetros ($PM_{2.5}$). Además de esta información, cada registro está categorizado en cuatro niveles, en base al riesgo ambiental que presentan las mediciones de O_3 y $PM_{2.5}$ para la fecha: bajo, medio, alto y extremo. En base a toda esta información, complete las misiones indicadas a continuación.

IMPORTANTE

Recuerde codificar numéricamente los valores de las columnas categóricas (`Year`, `Month`, `Day`, `Environmental_risk`) y normalizar las numéricas (O_3 y $PM_{2.5}$). Sea cuidadoso con el momento en que codifica y normaliza los valores, para evitar *data leakage*.

Misión 1: predicción de variables numéricas

Utilizando solo registros que no tengan valores faltantes para las columnas `Year`, `Month`, `Day`, O_3 y $PM_{2.5}$, construya al menos dos modelos predictivos que permitan inferir el valor de la variable $PM_{2.5}$ en base a las otras variables recién indicadas. Evalúe el rendimiento de estos modelos en un set de prueba independiente,

usando como métrica el *error cuadrático medio* (MSE), *error absoluto medio* (MAE) y *error porcentual absoluto medio* (MAPE). Finalmente, utilice el modelo con mejor rendimiento para completar los valores faltantes de la columna PM2.5, solo en aquellos registros que no tengan valores faltantes para las columnas Year, Month, Day y O3.

Misión 2: predicción de variables numéricas parte 2

Repita el procedimiento de la misión anterior, esta vez para completar los valores de la columna O3. Al finalizar este proceso, la base de datos solo debería tener valores faltantes para la columna `Environmental_risk`.

Misión 3: predicción de variables categóricas

Con la base de datos ya preparada, entrene al menos 2 clasificadores para predecir el valor de la variable `Environmental_risk`, a partir de todas las otras variables. Evalúe el rendimiento de estos modelos en un set de prueba independiente, usando como métrica el *balanced accuracy*. Finalmente, utilice el modelo con mejor rendimiento para completar los valores faltantes de la columna `Environmental_risk`.