



## Ejercicio Formativo 3 Capítulo 2

### Aspectos generales

- **Objetivos:** practicar los contenidos de modelos predictivos de aprendizaje supervisado.
- **ULTRA IMPORTANTE:** todas las celdas utilizadas deben estar ejecutadas al momento de desarrollar el ejercicio, de modo que las salidas generadas sean visibles.

### Descripción del problema

En este ejercicio trabajará con un conjunto de datos que describe información agregada sobre viviendas en distintos distritos de California, Estados Unidos. El objetivo es construir modelos supervisados para predecir la mediana del valor de las viviendas, comparar distintas alternativas y estudiar cómo su configuración afecta el desempeño. Para esto, deberá preparar los datos, construir variables derivadas, entrenar modelos de regresión, seleccionar hiperparámetros mediante validación y analizar el comportamiento de la solución final.

### Datos

El archivo de datos corresponde a `E3_datos.csv`. Cada fila representa un distrito habitacional y contiene las siguientes variables:

- `longitude`: longitud geográfica del distrito.
- `latitude`: latitud geográfica del distrito.
- `housing_median_age`: mediana de la antigüedad de las viviendas del distrito.

- `total_rooms`: número total de habitaciones registradas en el distrito.
- `total_bedrooms`: número total de dormitorios registrados en el distrito.
- `population`: población total del distrito.
- `households`: número total de hogares del distrito.
- `median_income`: mediana del ingreso del distrito.
- `median_house_value`: mediana del valor de las viviendas del distrito.
- `ocean_proximity`: categoría que indica la proximidad del distrito al océano.

La variable `median_house_value` será utilizada como variable objetivo en la parte supervisada del ejercicio. Esta variable no debe utilizarse para construir los clústers ni para ajustar las transformaciones no supervisadas.

## Misión 1: Preparación del conjunto de datos

Cargue el archivo `E3_datos.csv`, inspeccione sus variables y prepare una matriz de características adecuada para el análisis. Debe tratar los valores faltantes, transformar las variables categóricas que corresponda y construir al menos tres variables derivadas que ayuden a representar mejor las características de cada distrito. Justifique brevemente las decisiones tomadas en esta etapa.

## Misión 2: Modelo supervisado base

Construya un modelo supervisado base para predecir `median_house_value`. Para esto, entrene y evalúe al menos dos modelos de regresión, utilizando métricas adecuadas para comparar su desempeño.

## Misión 3: Selección y evaluación final del modelo

Seleccione uno de los modelos construidos en la Misión 2 y explore distintas configuraciones de sus hiperparámetros. Utilice un conjunto de validación para comparar las alternativas y justificar la configuración seleccionada, manteniendo el conjunto de test sin utilizar durante este proceso.

Una vez elegida la configuración final, evalúe el modelo una sola vez sobre el conjunto de test. Compare este resultado con el obtenido por el modelo base y analice los errores de predicción. En particular, determine si

el modelo presenta diferencias de desempeño entre las categorías de `ocean.proximity` o entre distritos con distintos niveles de ingreso.

Concluya si el proceso de selección permitió mejorar el modelo y señale al menos una limitación de la solución obtenida.