



IIC2115 – Programación como Herramienta para la Ingeniería (II/2026)

Ejercicio Formativo 4 Capítulo 2

Aspectos generales

- **Objetivos:** aplicar los contenidos de los modelos predictivos de aprendizaje no supervisado.
- **ULTRA IMPORTANTE:** todas las celdas utilizadas deben estar ejecutadas al momento de desarrollar el ejercicio, de modo que las salidas generadas sean visibles.

Descripción del problema

En este ejercicio trabajará con un conjunto de datos que describe información agregada sobre viviendas en distintos distritos de California, Estados Unidos. El objetivo es descubrir estructuras y construir perfiles de distritos mediante técnicas de aprendizaje no supervisado, sin utilizar etiquetas o categorías definidas previamente.

Para ello, deberá preparar los datos, construir variables que representen adecuadamente las características de cada distrito, aplicar técnicas de reducción de dimensionalidad y clustering, comparar distintas configuraciones y caracterizar los perfiles obtenidos desde una perspectiva territorial y socioeconómica.

Datos

El archivo de datos corresponde a `E4_datos.csv`. Cada fila representa un distrito habitacional y contiene las siguientes variables:

- **longitude:** longitud geográfica del distrito.
- **latitude:** latitud geográfica del distrito.

- `housing_median_age`: mediana de la antigüedad de las viviendas del distrito.
- `total_rooms`: número total de habitaciones registradas en el distrito.
- `total_bedrooms`: número total de dormitorios registrados en el distrito.
- `population`: población total del distrito.
- `households`: número total de hogares del distrito.
- `median_income`: mediana del ingreso del distrito.
- `median_house_value`: mediana del valor de las viviendas del distrito.
- `ocean_proximity`: categoría que indica la proximidad del distrito al océano.

En este ejercicio no existe una variable objetivo. Sin embargo, `median_house_value` no debe utilizarse para ajustar las transformaciones ni para construir los clústers. Una vez definidos los perfiles, podrá emplearse como una variable externa para ayudar a interpretarlos.

Misión 1: Preparación del conjunto de datos

Cargue el archivo `E4_datos.csv`, inspeccione sus variables y prepare una matriz de características adecuada para el análisis no supervisado.

Debe tratar los valores faltantes, transformar las variables categóricas que corresponda y construir al menos tres variables derivadas que representen mejor las características de los distritos. También debe considerar que las técnicas basadas en distancias pueden verse afectadas por la escala de las variables.

Justifique brevemente las decisiones tomadas y explique qué información busca capturar con las variables derivadas.

Misión 2: Reducción de dimensionalidad

Aplique una técnica de reducción de dimensionalidad sobre las características preparadas en la misión anterior, excluyendo `median_house_value`.

Determine cuántas dimensiones resulta razonable conservar y justifique su decisión mediante criterios apropiados. Analice qué variables tienen mayor influencia sobre las primeras dimensiones y proponga una interpretación para cada una de ellas.

Incluya al menos una visualización bidimensional de los distritos en el espacio reducido e identifique posibles patrones, concentraciones de observaciones o casos atípicos.

Misión 3: Construcción de perfiles de distritos

Utilice un algoritmo de clustering para agrupar distritos con características similares. Explore distintas cantidades de clústers y evalúe las soluciones mediante métricas y visualizaciones adecuadas.

Realice el clustering tanto sobre las características preparadas originalmente como sobre la representación de menor dimensionalidad obtenida en la Misión 2. Compare ambas alternativas y seleccione justificadamente una solución final.

La selección debe considerar tanto la separación entre los grupos como la posibilidad de interpretar los perfiles obtenidos.

Misión 4: Caracterización territorial y socioeconómica

Caracterice cada uno de los clústers seleccionados utilizando las variables originales y derivadas. Identifique las características que distinguen a cada grupo y asigne a cada perfil un nombre breve que sintetice su interpretación.

Estudie además la distribución geográfica de los perfiles mediante `longitude` y `latitude`, y analice su relación con `ocean_proximity`.

Una vez contruidos los clústers, compare también la distribución de `median_house_value` entre los perfiles. Recuerde que esta variable puede utilizarse para interpretar los resultados, pero no para definir los grupos.

Misión 5: Evaluación e interpretación de resultados

Evalúe la calidad y estabilidad de los perfiles obtenidos. Para ello, analice cómo cambian los resultados al modificar decisiones relevantes, como la cantidad de clústers, las variables utilizadas o la inicialización del algoritmo.

Discuta si los perfiles representan grupos claramente diferenciados, qué observaciones resultan difíciles de clasificar y qué limitaciones presenta el análisis realizado.

Elabore una conclusión general sobre la estructura identificada en los distritos de California. Su análisis debe apoyarse en métricas, tablas y visualizaciones adecuadas.