

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2115 - Programación como herramienta para la ingeniería


Modelos predictivos de aprendizaje no supervisado


Profesor: Hans Löbel


Repasemos brevemente qué es Machine Learning

- Técnicas computacionales que usan **datos** para realizar **tareas predictivas** (clasificación, regresión, reducción de dimensionalidad, clustering, etc.)
- Típicamente mejoran su **rendimiento** a través de la experiencia → **aprendizaje** desde los **datos**.
- Foco es distinto a la estadística: técnicas de ML buscan realizar **tareas/predicciones** con la mayor precisión posible, más que entender el fenómeno subyacente.










Clustering genera grupos con datos similares de manera no supervisada



Type	Level	Description
Location	I/B [†]	Geocoded position of the unit
SES	I B	Socioeconomic status
Aesthetic	I/B	Aesthetic perception index of the nearest geocoded image (individual) or averaged at the urban block level
Political	I/B	Proportion of a political choice in the Constitutional plebiscite or in the Chilean Presidential Elections (first round)
Land use	I/B	Proportion/ $M^{2\ddagger}$ of land use of the urban block according to a land use typology*
Demographic	I B	Sex, age, proportion of immigrants Age, proportion of immigrants/women



Reducción de dimensionalidad permite representar datos con muchas variables en un espacio de menor dimensión para revelar estructura y similitudes

Espacio original (alta dimensión)

Cada observación se describe por muchas variables

	Ingreso promedio	Densidad poblacional	Acceso a transporte	Áreas verdes	Uso de suelo	...
Barrio 1						...
Barrio 2						...
Barrio 3						...
...	...	...	...	...	...	...
Barrio n						...

Decenas o cientos de variables
(características)


Reducción de
dimensionalidad



Se construyen nuevas
variables que combinan
la información original

Espacio reducido (2D)

Cada punto es un barrio



Puntos cercanos = observaciones similares

La distancia en el plano refleja similitud considerando todas las variables originales.

Color (solo para referencia visual):
zona del territorio

Zona A

Zona B

Zona C


Zona D

Zona E

Zona F

El color no se usa para construir la representación.

(casi) Todas las técnicas de ML usan el mismo esquema de procesamiento





Características

Etiqueta

Población	Superficie (km²)	Densidad poblacional por km²	Ingreso anual promedio per cápita en dólares
3.500.000	600	5.833	\$45.000
1.200.000	150	8.000	\$35.000
2.800.000	300	9.333	\$30.000
900.000	350	2.571	\$25.000
600.000	400	1.500	\$20.000
750.000	500	1.500	\$15.000
300.000	200	1.500	\$10.000
1.100.000	250	4.400	\$9.000
2.300.000	450	5.111	\$8.000
500.000	180	2.777	\$7.000
800.000	190	4.211	\$6.000
950.000	220	4.318	\$5.700
410.000	300	1.367	\$5.250
1.500.000	280	5.357	\$70.000
670.000	330	2.030	\$33.000
390.000	210	1.857	\$11.000

Cada dato puede verse como un vector/punto en el espacio de características



Esto hace que datos y tareas puedan interpretarse de manera más intuitiva desde un punto de vista geométrico


Cerremos con un caso real de estudio



¿Cómo explorar miles de imágenes sin etiquetas?

Una colección de imágenes sin etiquetas

- Cada imagen es un dato
- No tenemos una categoría objetivo
- Queremos encontrar similitudes visuales



? ¿Paisajes?


? ¿Retratos?

? ¿Colores similares?

? ¿Estilos similares?

? ¿Composiciones similares?

Cada imagen se representa por muchas características



Colores



Texturas



Formas




Composición



Patrones
visuales

Imágenes parecidas quedan cerca


- Dos imágenes similares deberían tener representaciones vectoriales similares
- La distancia entre vectores captura similitud visual
- No se usan etiquetas para hacer esta comparación
- Esto calza exactamente con la exploración mediante técnicas de aprendizaje no supervisado



Del espacio complejo a un mapa visual

- Se construye una representación utilizando técnicas no lineales de reducción de dimensionalidad
- El mapa 2D resultante permite navegar la colección

Cada imagen vive originalmente en un espacio de muchas características.




Representación de menor dimensión




Aparece estructura sin haber sido etiquetada

- Zonas con colores, estilos o temas similares
- Transiciones graduales ente tipos de imágenes
- Casos raros o difíciles de ubicar
- Posibles grupos, sin haberlos definido antes



Veamos cómo funciona el sistema en la práctica



(<https://artsexperiments.withgoogle.com/tsnemap/>)

Algunos aspectos relevantes para la resolución de problemas

- Separar construcción e interpretación: no usar variables objetivo o de contraste para construir clústers o proyecciones.
- Cuidar la representación de los datos: definir bien variables, transformaciones, escalamiento y variables derivadas.
- Justificar configuraciones: no basta con aplicar PCA, t-SNE o clustering, hay que explicar las decisiones tomadas.
- Interpretar con el dominio: caracterizar grupos, proyecciones o atípicos usando tablas, métricas y visualizaciones.
- Evitar contaminación de datos al combinar con aprendizaje supervisado: ajustar transformaciones sin usar información indebida del conjunto de prueba.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2115 - Programación como herramienta para la ingeniería

Modelos predictivos de aprendizaje no supervisado

Profesor: Hans Löbel