Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

IIC2115 - Programación como herramienta para la ingeniería

Modelos Predictivos basados en Machine Learning

Profesor: Hans Löbel

¿Cómo puedo saber si en una foto hay un perro o un gato?

(usando un computador, lógicamente)

¿ ?

Cat

Dog

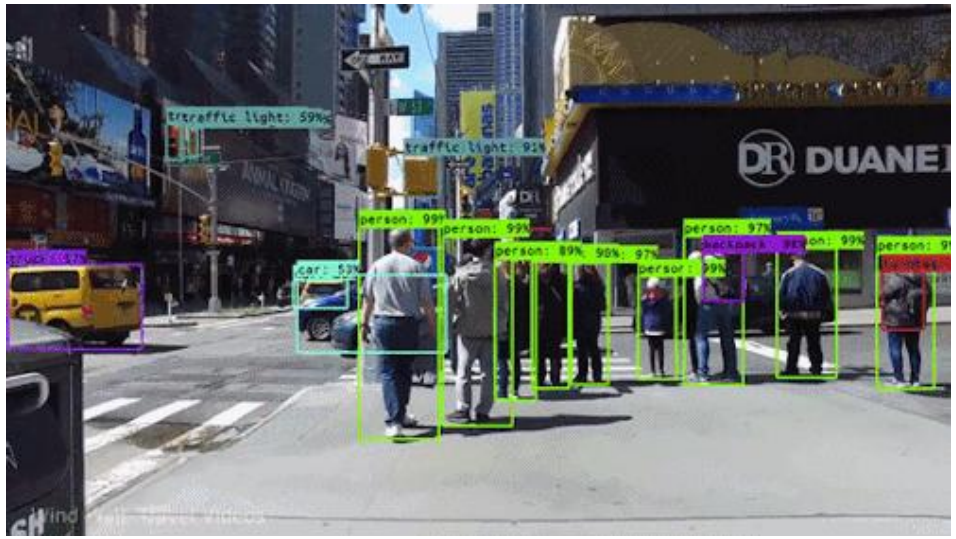

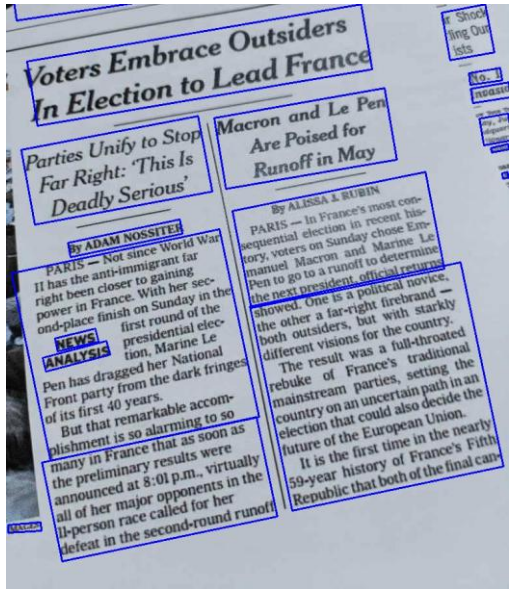

Generated Question	Answer
How many bears are laying on the ice?	"two"
What are the two animals laying on the ice?	"bears"
What are the bears doing?	"laying down"
Two bears are laying down on what?	"ice"
Where are the bears laying?	"on the ice"
Are the bears on the ice?	"yes"

A dog wearing a Superhero outfit with red cape flying through the sky

¿Qué es el análisis de datos en Python?

- A través de este análisis, buscamos responder preguntas relevantes, o descubrir aspectos desconocidos, en base a la evidencia dada por los datos
- Inicialmente exploraremos los datos tabulares, para luego pasar a otros tipos de datos en el resto del curso.
- Desde un punto de vista práctico, buscaremos realizar las siguientes tareas:
  - Exploración de distintas dimensiones
  - Limpieza, corrección y transformación
  - Análisis estadístico
  - Construir modelos predictivos a partir de los datos usando Machine Learning

En este capítulo nos centraremos en scikit-learn

- Implementa gran cantidad de algoritmos predictivos y de procesamiento de datos, basados en Machine Learning.
- Clasificación, regresión, *clustering*, reducción de dimensionalidad, selección de modelos y más.
- Permite una fácil integración con Pandas y librerías de visualización.

Antes de revisar *scikit-learn*, necesitamos una breve introducción a Machine Learning (Aprendizaje de Máquina)

¿Qué es Machine Learning (ML)?

- En simple, se trata de algoritmos que procesan datos para realizar tareas predictivas (clasificación, regresión, reducción de dimensionalidad, clustering, etc.)

- Más específicamente, ML se centra en el estudio de algoritmos que mejoran su rendimiento en una tarea, a través de la experiencia (aprendizaje desde los datos).

- Foco es distinto a la estadística: técnicas de ML buscan resolver las tareas con la mayor precisión posible, más que entender el fenómeno subyacente.

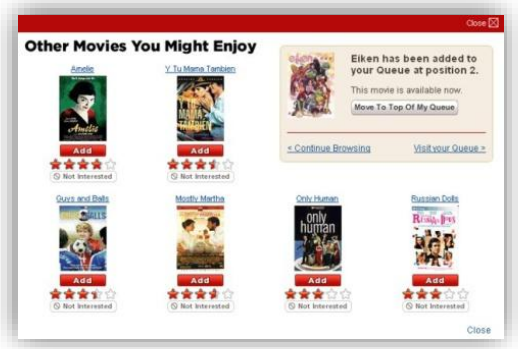

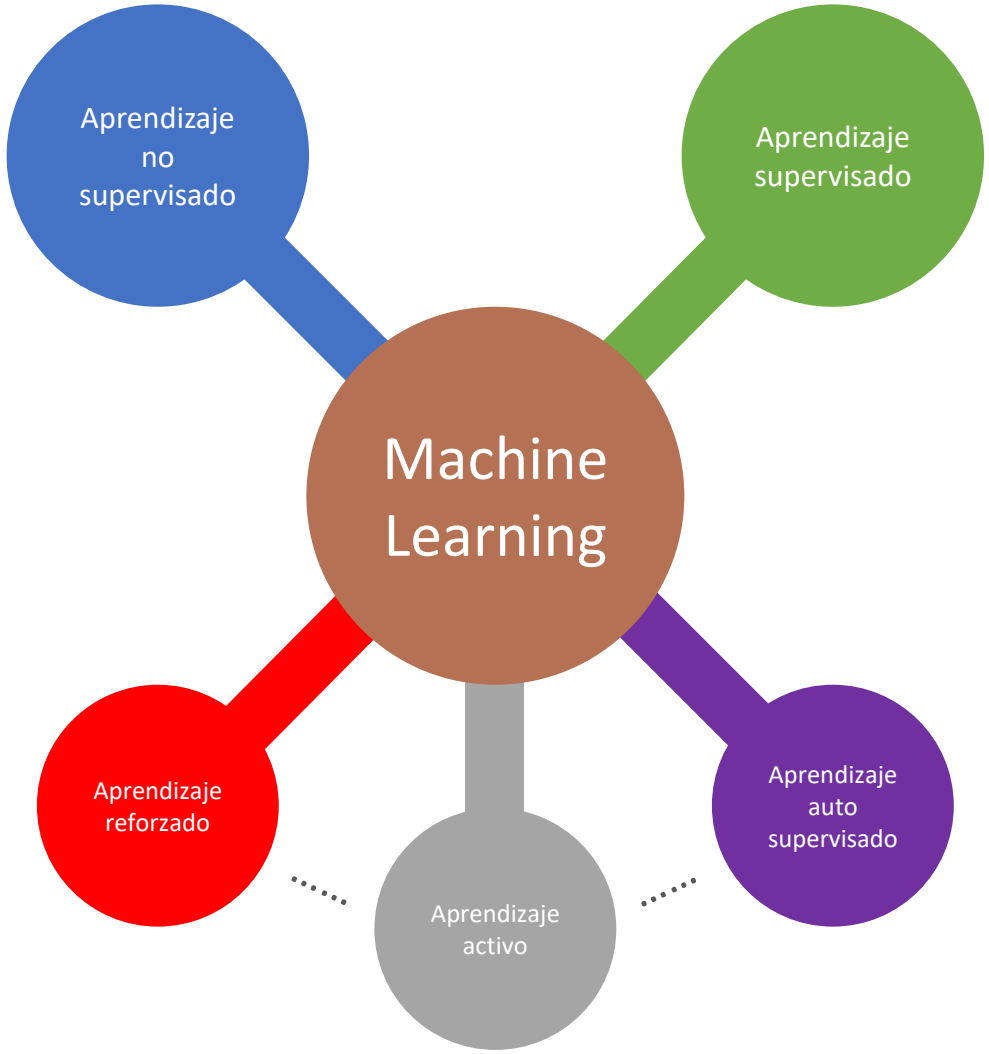
Aprendizaje no supervisado
Aprendizaje supervisado
Machine Learning
Aprendizaje reforzado
Aprendizaje activo
Aprendizaje auto supervisado

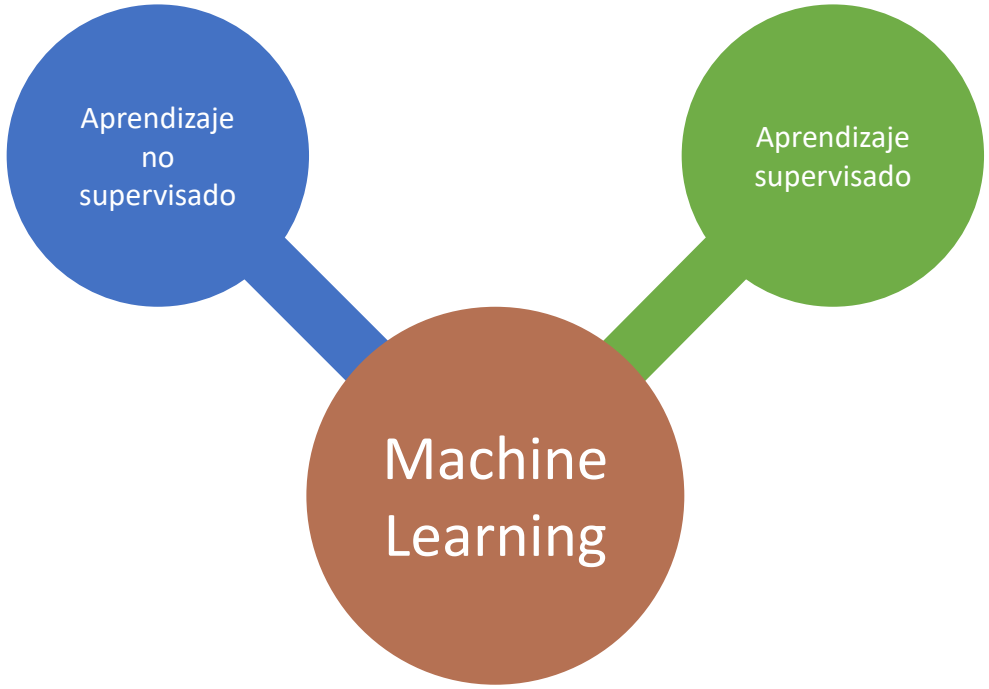
Aprendizaje no supervisado
Aprendizaje supervisado
Machine Learning

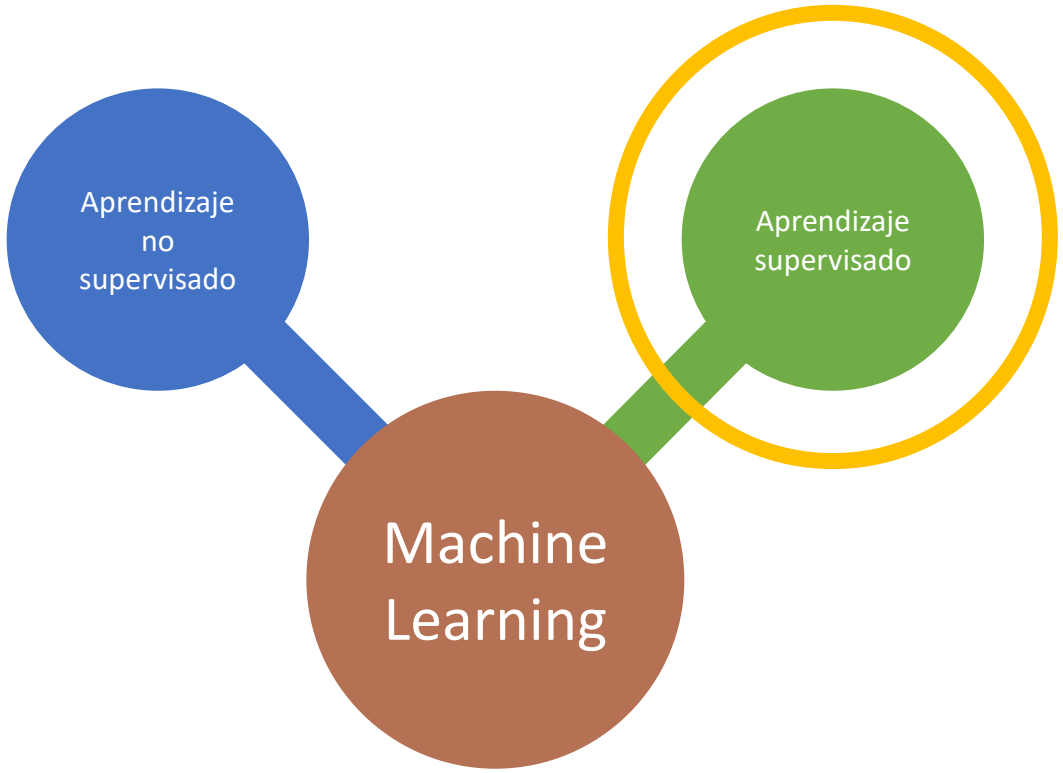
Aprendizaje
no
supervisado
Aprendizaje
supervisado
Machine
Learning

Cat

Dog

¿ ?

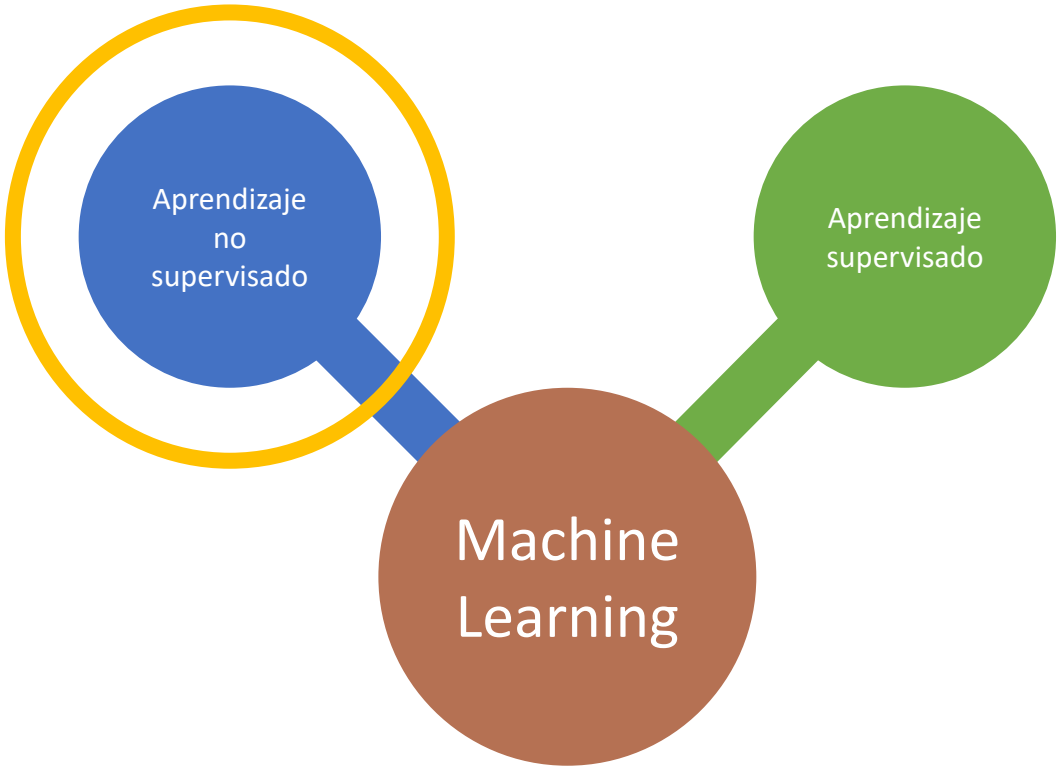
Aprendizaje
no
supervisado
Aprendizaje
supervisado
Machine
Learning

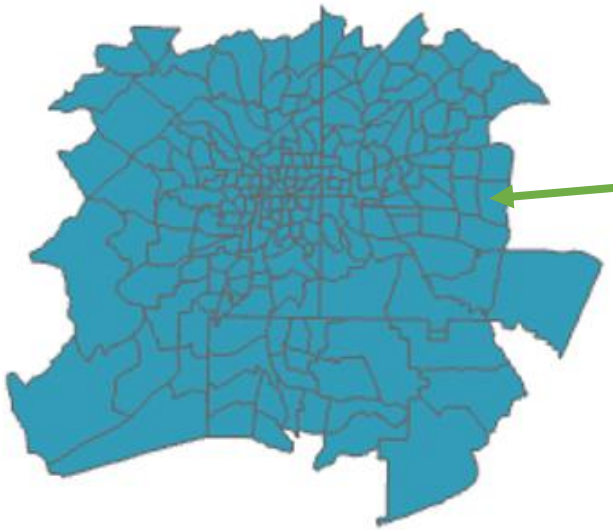

Type	Level	Description
Location	I/B†	Geocoded position of the unit
SES	I B	Socioeconomic status
Aesthetic	I/B	Aesthetic perception index of the nearest geocoded image (individual) or averaged at the urban block level
Political	I/B	Proportion of a political choice in the Constitutional plebiscite or in the Chilean Presidential Elections (first round)
Land use	I/B	Proportion/M^2‡ of land use of the urban block according to a land use typology*
Demographic	I B	Sex, age, proportion of immigrants Age, proportion of immigrants/women

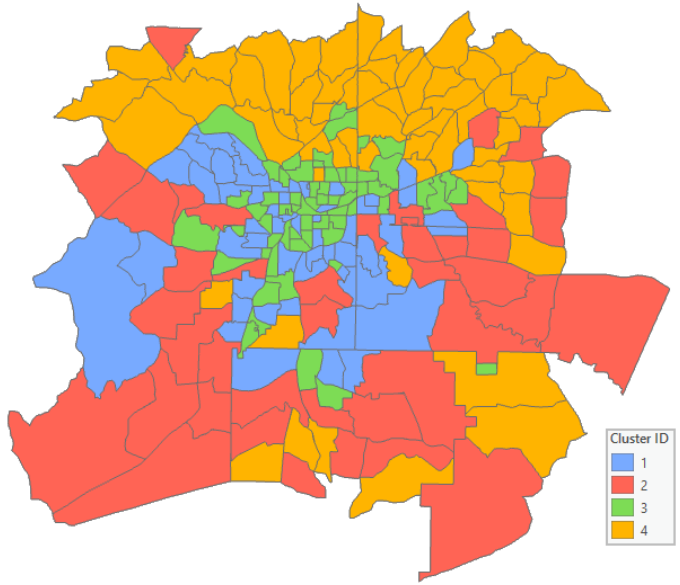

(casi) Todas las técnicas de ML usan el mismo esquema de procesamiento

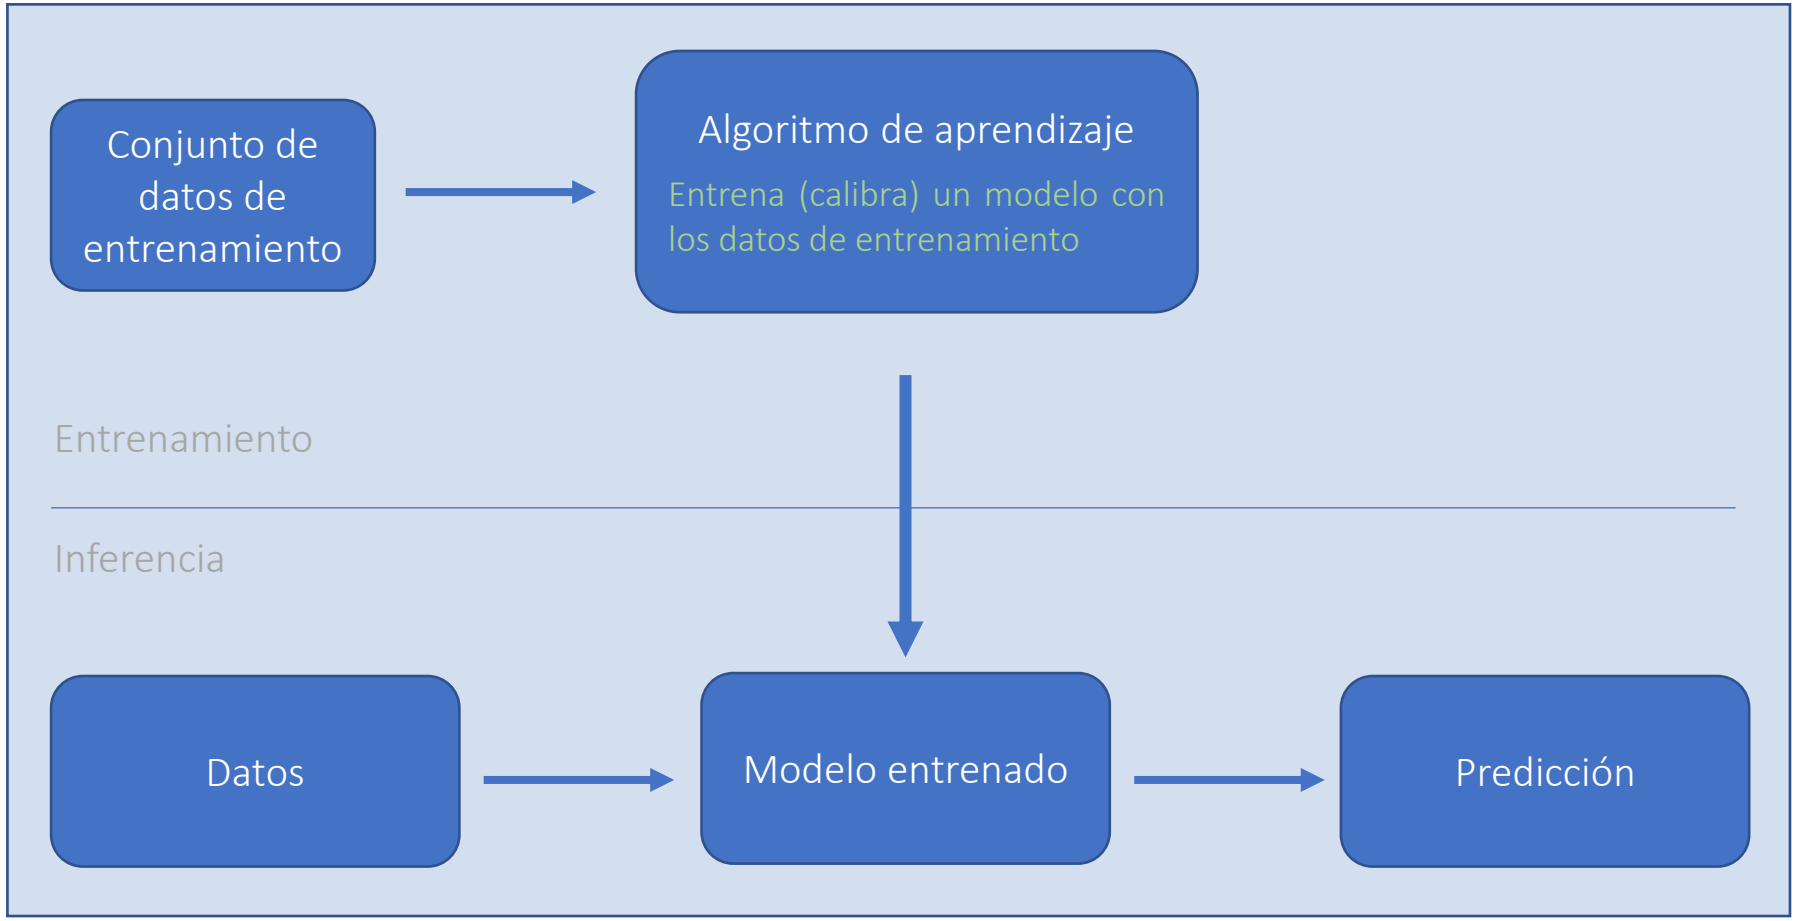

Técnicas de ML trabajan sobre datos multidimensionales

- Cada dato esta caracterizado por una serie de características = *features* = atributos = variables.
- Muchas veces, los datos poseen además una etiqueta = *label* = rótulo.

Datos de Entrenamiento

Características			Etiqueta
Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
3.500.000	600	5.833	$45.000
1.200.000	150	8.000	$35.000
2.800.000	300	9.333	$40.000
900.000	350	2.571	$30.000
600.000	400	1.500	$28.000
750.000	500	1.500	$32.000
300.000	200	1.500	$27.000
1.100.000	250	4.400	$36.000

Técnicas de ML trabajan sobre datos multidimensionales

- Cada dato del conjunto de entrenamiento puede considerarse como un vector en el espacio de características.
- La cantidad de características define la dimensionalidad del vector.
- El espacio donde viven los vectores se conoce como espacio de características.

Datos de Entrenamiento

Características			Etiqueta
Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
3.500.000	600	5.833	$45.000
1.200.000	150	8.000	$35.000
2.800.000	300	9.333	$40.000
900.000	350	2.571	$30.000
600.000	400	1.500	$28.000
750.000	500	1.500	$32.000
300.000	200	1.500	$27.000
1.100.000	250	4.400	$36.000

Cada dato puede verse como un vector/punto en el espacio de características

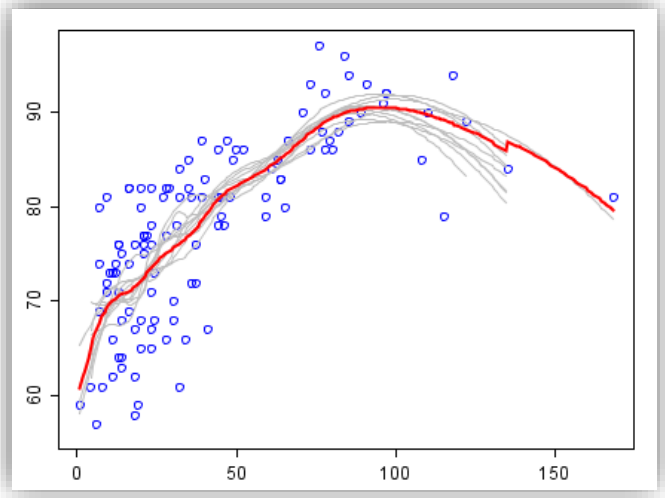

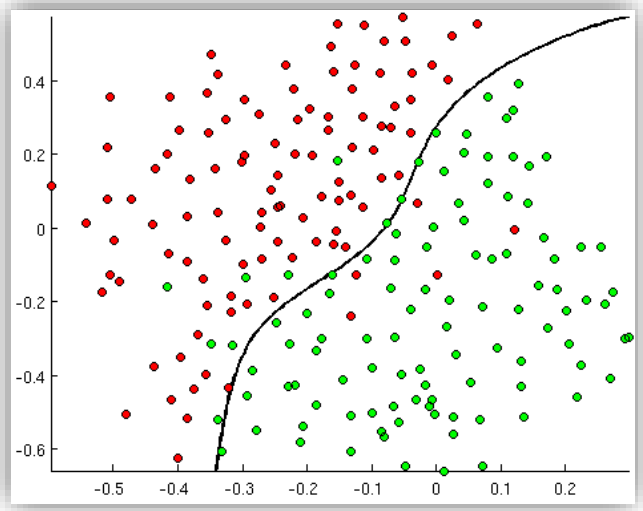

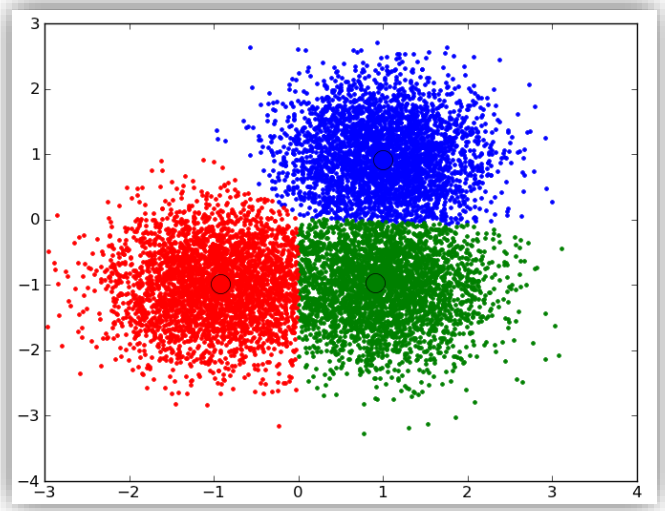

Esto hace que datos y tareas puedan interpretarse de manera más intuitiva desde un punto de vista geométrico

Teniendo las bases cubiertas, podemos revisar *scikit-learn*

En este curso usaremos scikit-learn

- scikit-learn es el módulo para ML más conocido y utilizado en Python.
- Su principal atractivo es una interfaz limpia, uniforme y simple, que facilita la exploración y permite la integración con otros paquetes, como Pandas.
- Posee además de una completa documentación en línea (https://scikit-learn.org/).

Esquema de datos de scikit-learn es similar a Pandas

- Datos son representados por una matriz de *características* y un vector objetivo de etiquetas.

- Las características de los ejemplos se almacenan en una matriz de característcas (X), de tamaño [n_samples, n_features] (esta matriz típicamente será un DataFrame, pero puede ser de otro tipo).

- El vector objetivo (y) contiene la etiqueta para cada ejemplo y tiene tamaño [n_samples, 1] (este vector típicamente será un Series, pero puede ser de otro tipo).

- Y eso es todo…

Esquema de datos es similar a Pandas

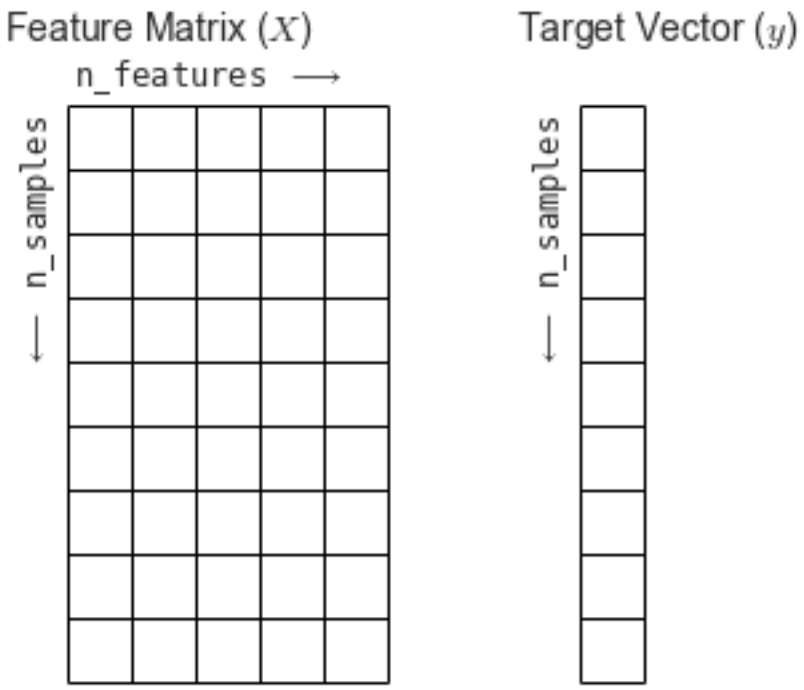

Uso de los modelos es simple y directo

- En general, un caso de uso típico en scikit-learn es como el siguiente:
  1. Elegir el modelo adecuado, importando la clase correspondiente desde *sklearn*.
  2. Obtener o generar matriz X y vector y.
  3. Entrenar el modelo llamando al fit(X, y).
  4. Aplicar el modelo al conjunto de datos de prueba, usando el método predict().

Uso de los modelos es simple y directo

- El fácil uso de scikit-learn se basa en los siguientes conceptos principales:
  - Consistente: todos los modelos comparten una interfaz con unas pocas funciones.
  - Sucinta: solo usa clases propias para los algoritmos. Para todo el resto utiliza formatos estándares (datos en DataFrame, por ejemplo).
  - Útil: los parámetros por defecto son útiles para estimar adecuadamente los modelos.
- En resumen, requiere muy poco esfuerzo utilizarla y obtener resultados rápidamente.

Podrán utilizar múltiples modelos/algoritmos en este capítulo

- k-NN
- Regresiones SVM
- Árboles de decisión
- Ensambles
- Redes neuronales
- K-Means Clustering
- PCA, tSNE
- y más…

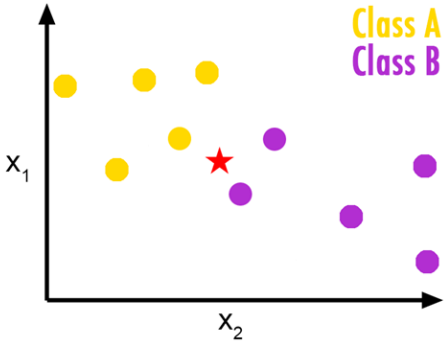

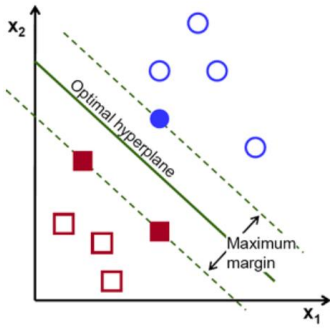

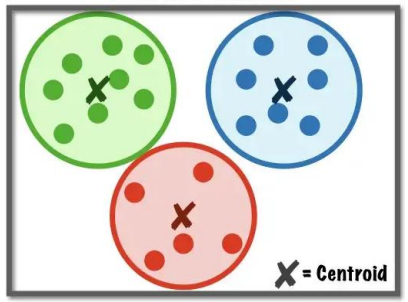

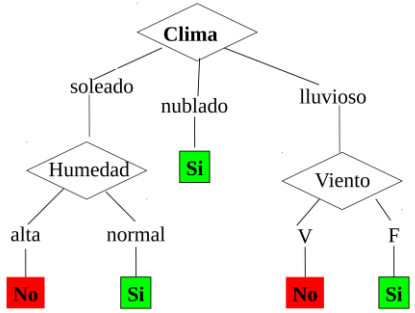

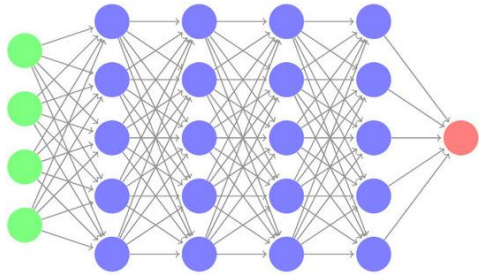

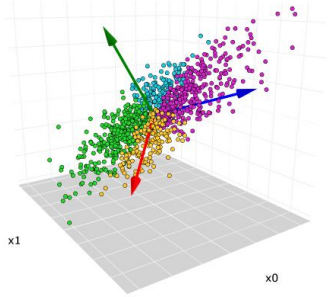

A pesar de ser clave, los datos de entrenamiento no lo son todo

- En general, los algoritmos de aprendizaje viven y mueren por los datos de entrenamiento.
- Lamentablemente, tener un buen conjunto de entrenamiento no asegura tener buen rendimiento con datos no vistos previamente (buena generalización).
- La complejidad del modelo pasa a ser un tema central.
- Típicamente la complejidad se asocia con la cantidad de factores que pueden considerar el modelo, o cuánto puede aprender.

Subajuste (*underfitting*)

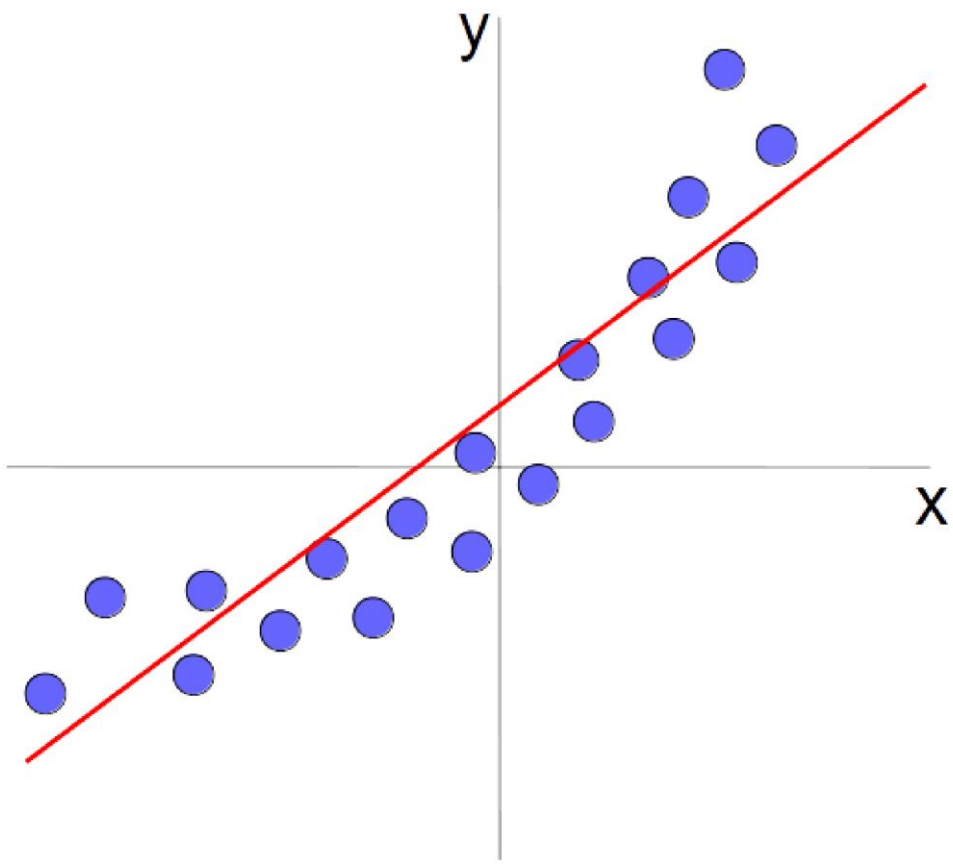

Sobreajuste (overfitting)

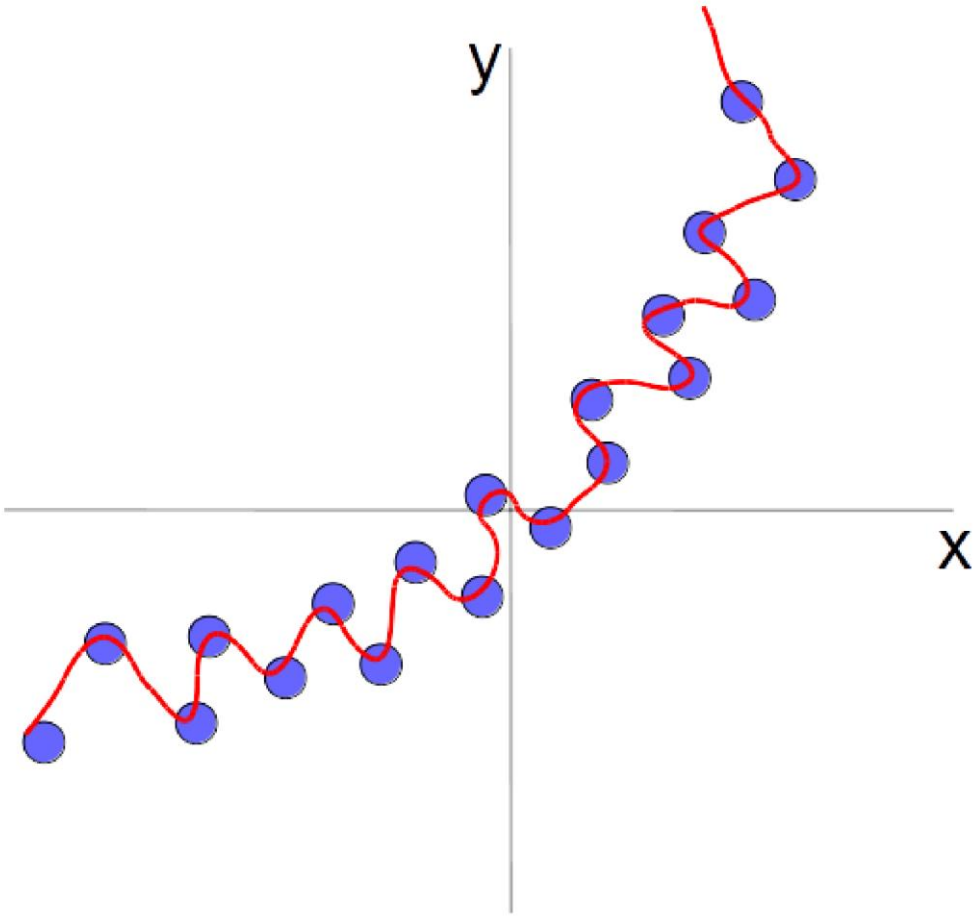

Ajuste correcto del modelo

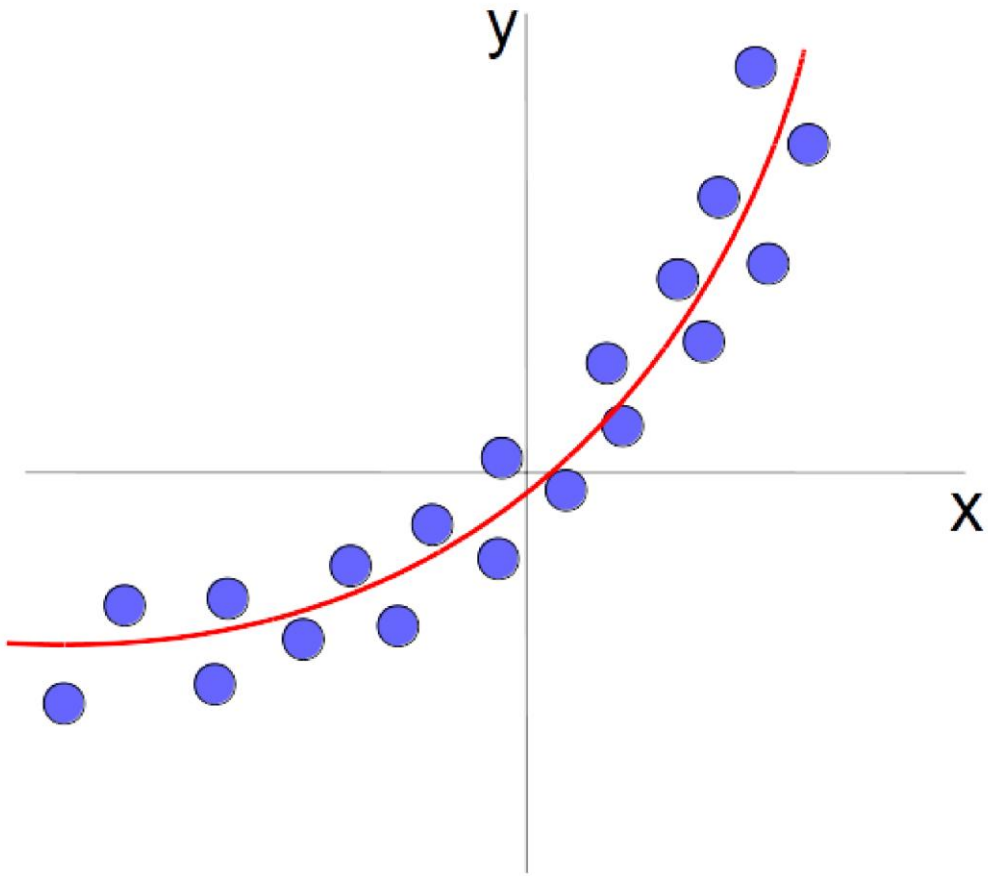

¿Cómo puedo entonces elegir el modelo adecuado?

- Lo primero que necesitamos es una manera de medir el rendimiento de un modelo.
- Para esto, típicamente debemos definir dos cosas: una métrica de rendimiento y un conjunto de prueba.
- La métrica de rendimiento estará dada generalmente por la tarea a resolver.
- El conjunto de pruebas debe venir de la misma distribución de datos que el conjunto de entrenamiento (puede ser un subconjunto de este).
- Etiquetas del conjunto de prueba deben ser completamente desconocidas para el modelo (solo se conocen al evaluar el rendimiento).

	Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
Entrenamiento	3.500.000	600	5.833	$45.000
	1.200.000	150	8.000	$35.000
	2.800.000	300	9.333	$40.000
	900.000	350	2.571	$30.000
	600.000	400	1.500	$28.000
	750.000	500	1.500	$32.000
	300.000	200	1.500	$27.000
	1.100.000	250	4.400	$36.000
	2.300.000	450	5.111	$42.000
	500.000	180	2.777	$29.000
Prueba/Test	800.000	190	4.211	?
	950.000	220	4.318	
	410.000	300	1.367	
	1.500.000	280	5.357	
	670.000	330	2.030	
	390.000	210	1.857	

Una forma clara de ver esto es con conjuntos de datos disjuntos

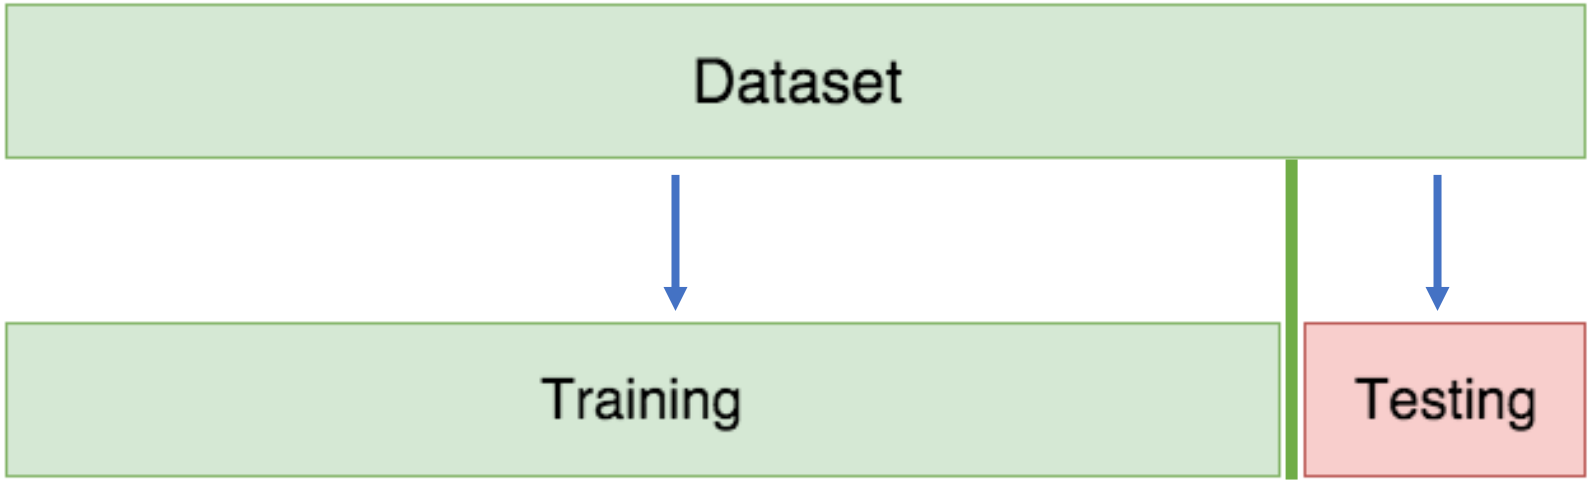

Rendimiento está íntimamente relacionado con la complejidad de los modelos

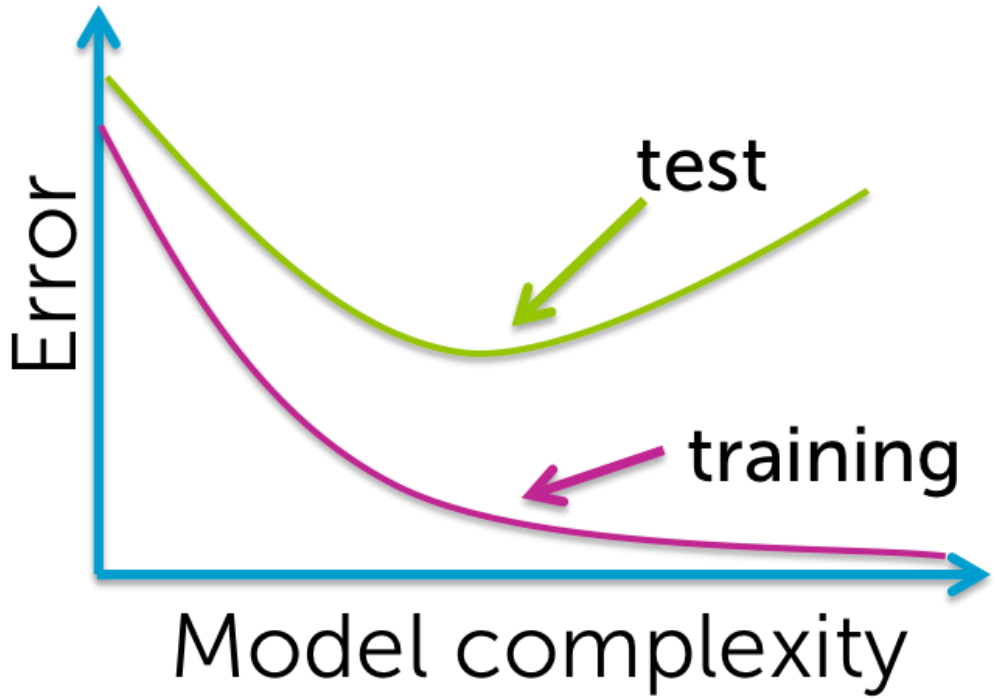

Típicamente, un modelo sobreajustado tendrá un rendimiento mucho mejor en el conjunto de entrenamiento que en el de test

scikit-learn también facilita el proceso de selección de modelos

- El primer paso consiste en explorar, analizar y preparar los datos.
- En base a esto, se eligen algunos modelos candidatos y se evalúa su rendimiento en entrenamiento y test.
- También es posible utilizar esquemas más robustos de evaluación, como la validación cruzada.
- scikit-learn entrega una gran cantidad de métricas de rendimiento para distintos tipos de problema.
- Se encuentran en el módulo `sklearn.metrics`
- En la práctica, las más usadas son *accuracy*, *precision*, *recall*, error cuadrático medio y matriz de confusión.

Cerremos con un caso real de estudio

Cerremos con un caso real de estudio

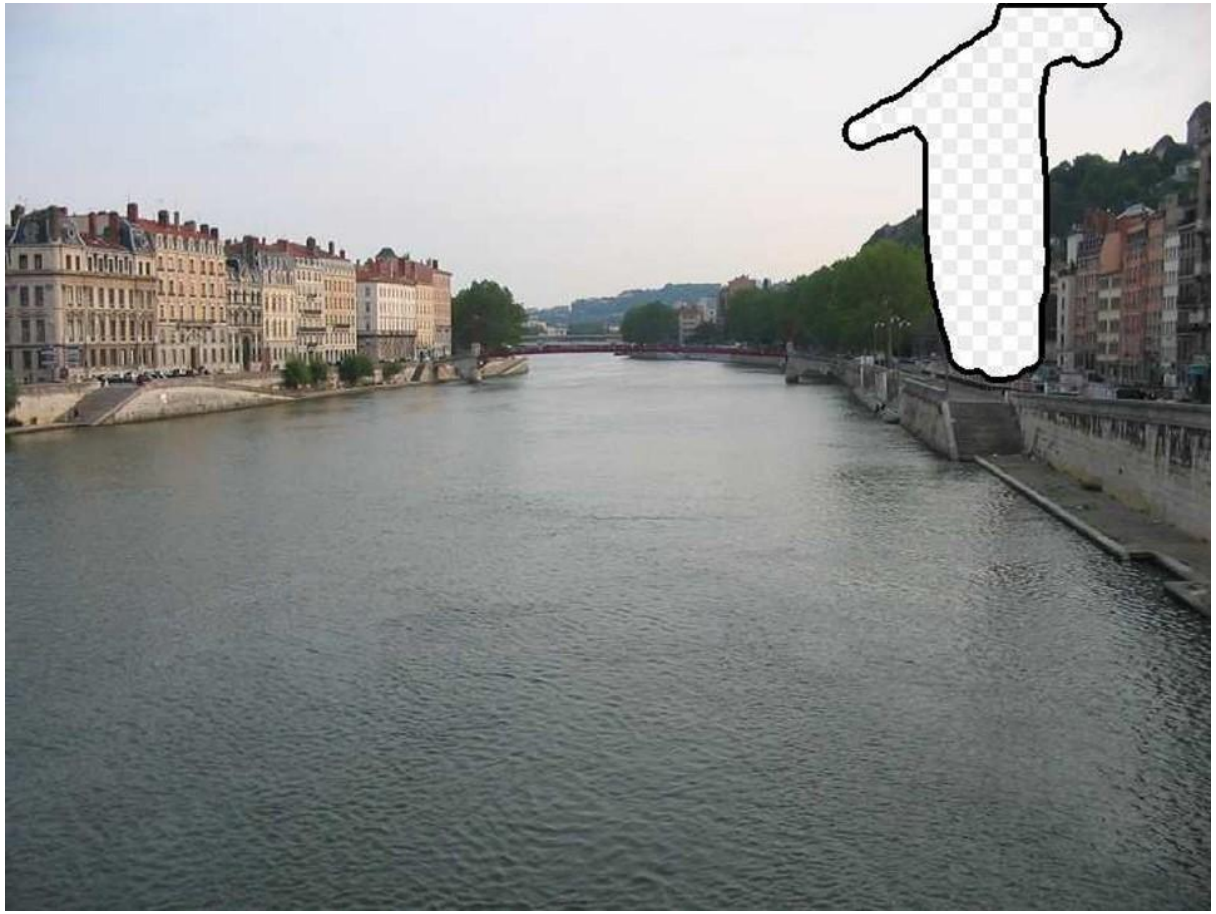

Cerremos con un caso real de estudio

Recordemos que (casi) todas las técnicas de ML usan el mismo esquema de procesamiento

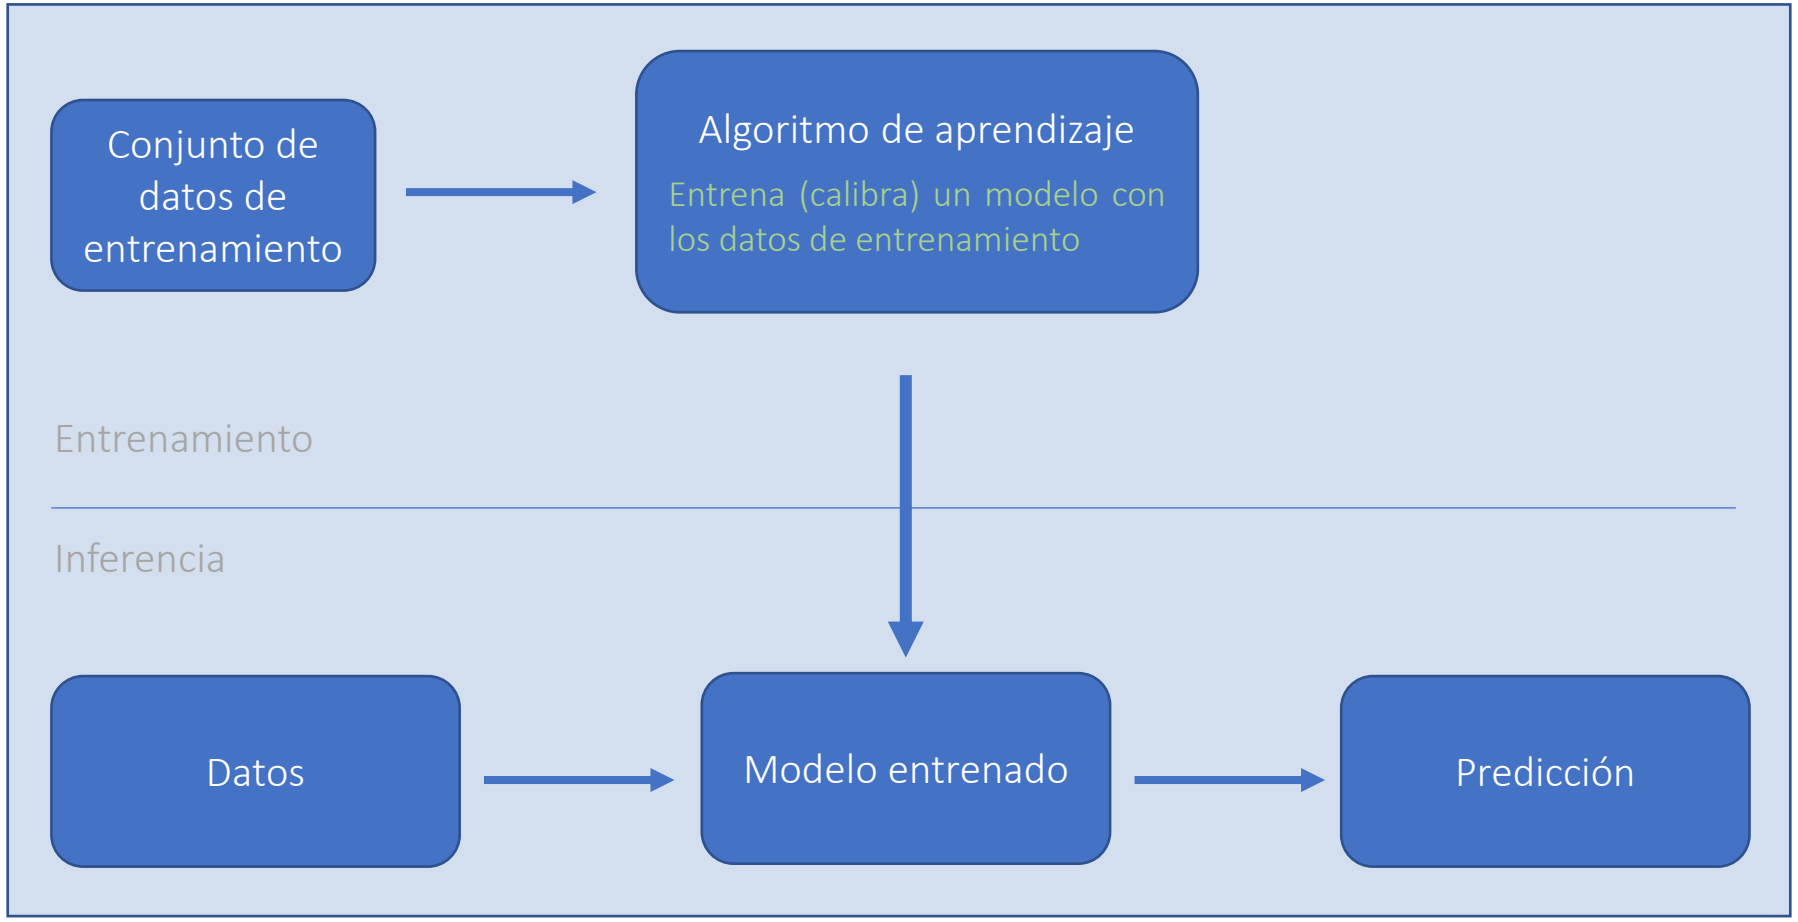

Datos de entrenamiento se generan a partir de imágenes reales

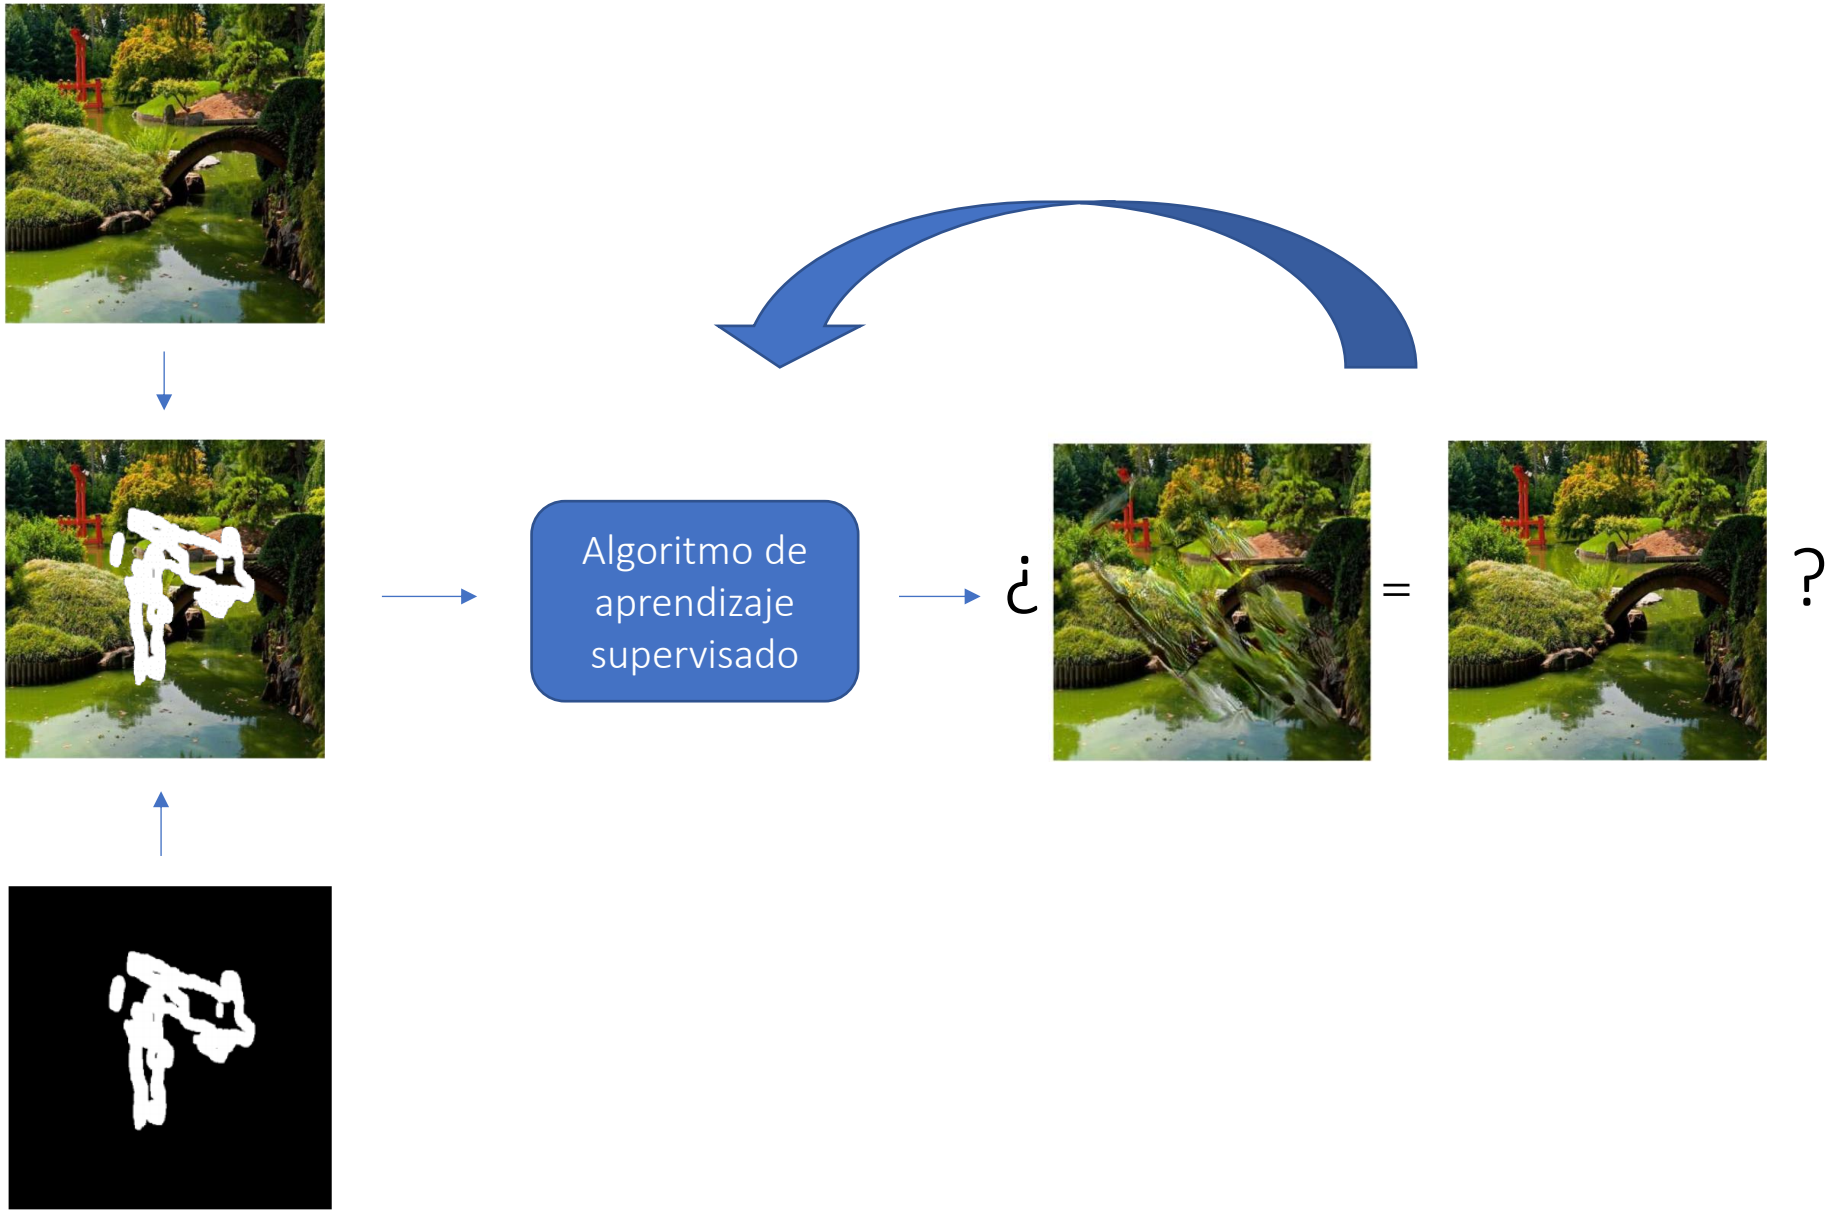
Algoritmo de aprendizaje supervisado
¿
=
?

Veamos cómo funciona el sistema en la práctica

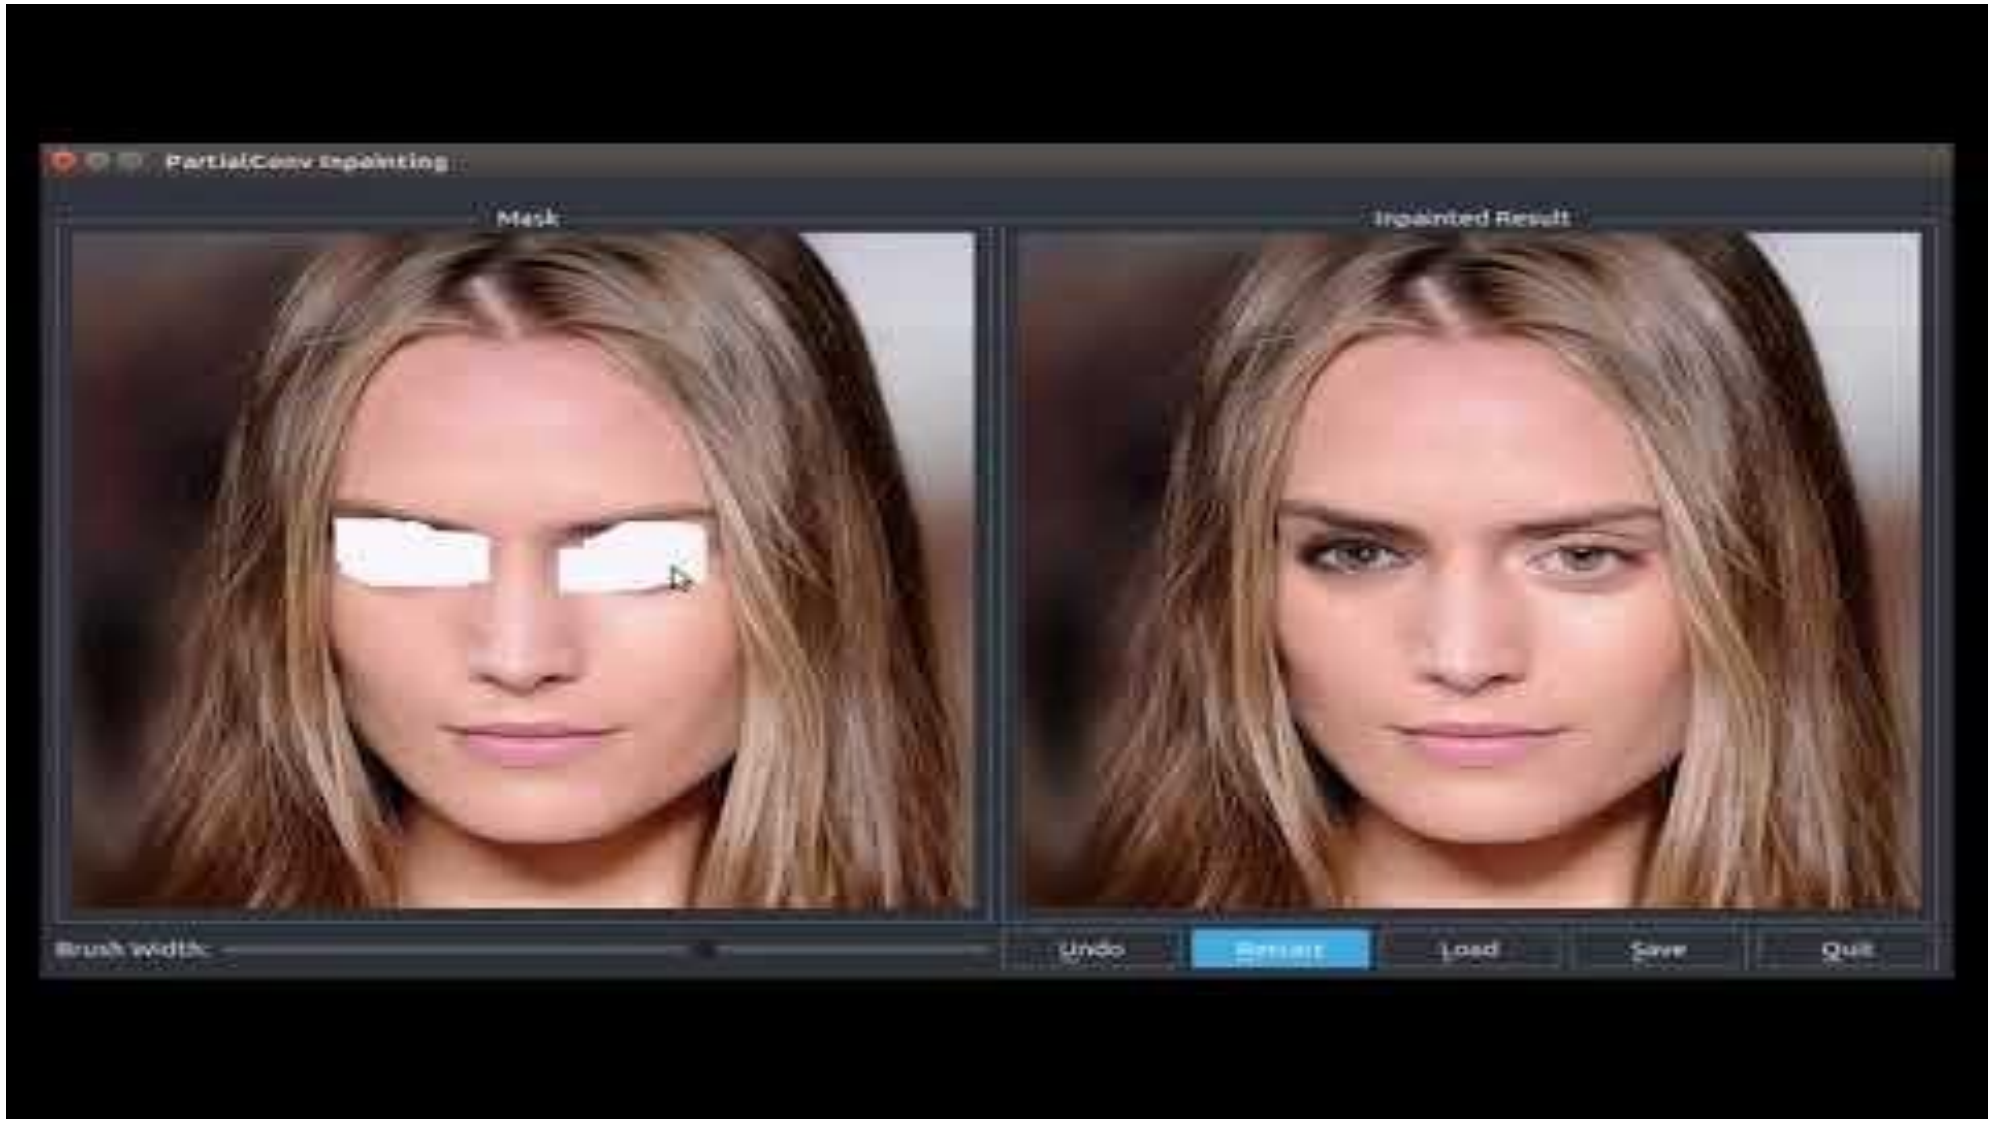

(https://youtu.be/gg0F5JjKmhA)

En resumen…

- ML se centra en algoritmos/modelos que aprenden de los datos para resolver una tarea
- scikit-learn permite hacer ML en Python de manera práctica y rápida
- (casi) Todas las técnicas de ML funcionan de la misma manera
- Qué técnica usar dependerá de la tarea y los datos disponibles, pero es posible elegir en base a métricas de rendimiento
- Todo esto y mucho más en el curso ICT3115 – Sistemas Urbanos Inteligentes e IIC3697 – Aprendizaje Profundo (ambos dictados los primeros semestres)

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

IIC2115 - Programación como herramienta para la ingeniería

Modelos Predictivos basados en Machine Learning

Profesor: Hans Löbel