Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

IIC2115 - Programación como herramienta para la ingeniería

Modelos predictivos de aprendizaje supervisado

Profesor: Hans Löbel

¿Cómo puedo saber si en una foto hay un perro o un gato?

(usando un computador y sin preguntarle a un asistente, obviamente)

¿ ?

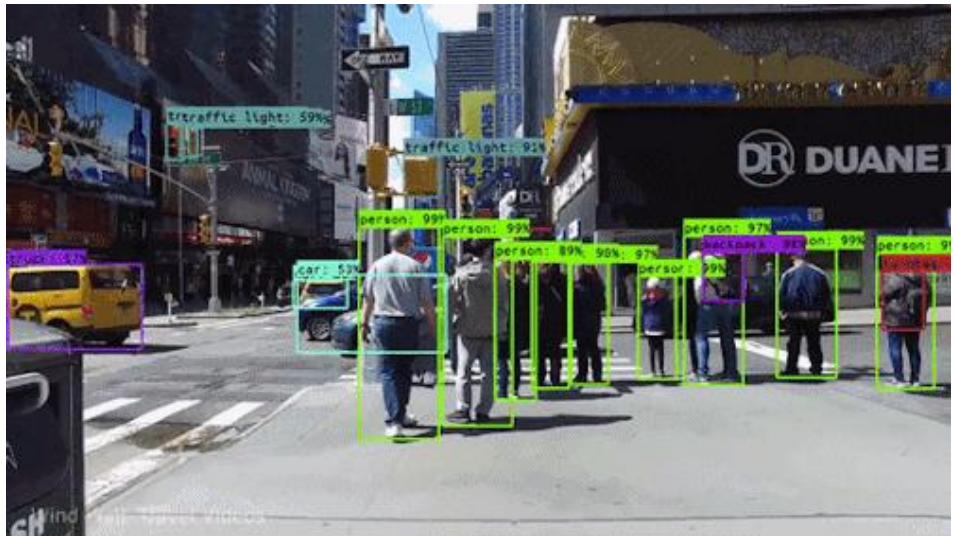

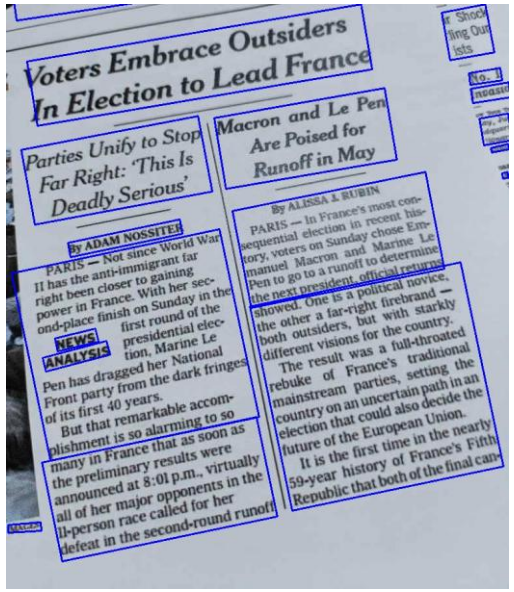

Generated Question	Answer
How many bears are laying on the ice?	"two"
What are the two animals laying on the ice?	"bears"
What are the bears doing?	"laying down"
Two bears are laying down on what?	"ice"
Where are the bears laying?	"on the ice"
Are the bears on the ice?	"yes"

A dog wearing a Superhero outfit with red cape flying through the sky

En simple, Machine Learning será para nosotros el estudio sobre cómo hacer predicciones a partir de ejemplos

- Adecuado para problemas donde la programación “tradicional” no es posible (reglas, algoritmos o procedimientos explícito).
- Éxito o fracaso depende del rendimiento en ejemplos no “vistos” previamente.
- Metodologías y protocolos para “entrenar” buenos modelos son el foco de este capítulo.

Con respecto a la herramienta específica para ML, en este capítulo nos centraremos en scikit-learn

- Implementa gran cantidad de algoritmos y modelos predictivos, basados en Machine Learning.
- Clasificación, regresión, *clustering*, reducción de dimensionalidad, selección de modelos y más.
- Permite una fácil integración con Pandas y librerías de visualización.

Antes de revisar *scikit-learn* y el tipo de problemas en este capítulo, necesitamos una breve introducción a los elementos centrales de Machine Learning

Ahora con algo más de detalle,
¿Qué es Machine Learning?

- Técnicas computacionales que usan datos para realizar tareas predictivas (clasificación, regresión, reducción de dimensionalidad, clustering, etc.)

- Típicamente, estas técnicas (modelos, algoritmos, etc.) mejoran su rendimiento predictivo, a través de la experiencia → aprendizaje desde los datos.

- Foco es distinto a la estadística: técnicas de ML buscan realizar tareas/predicciones con la mayor precisión posible, más que entender el fenómeno subyacente.

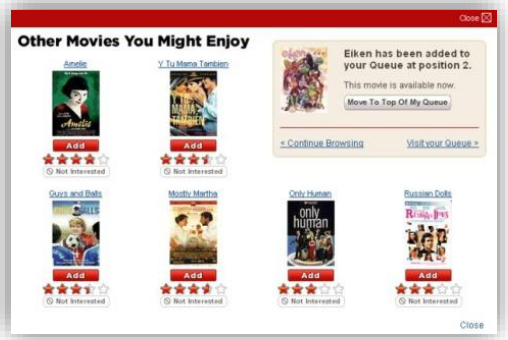

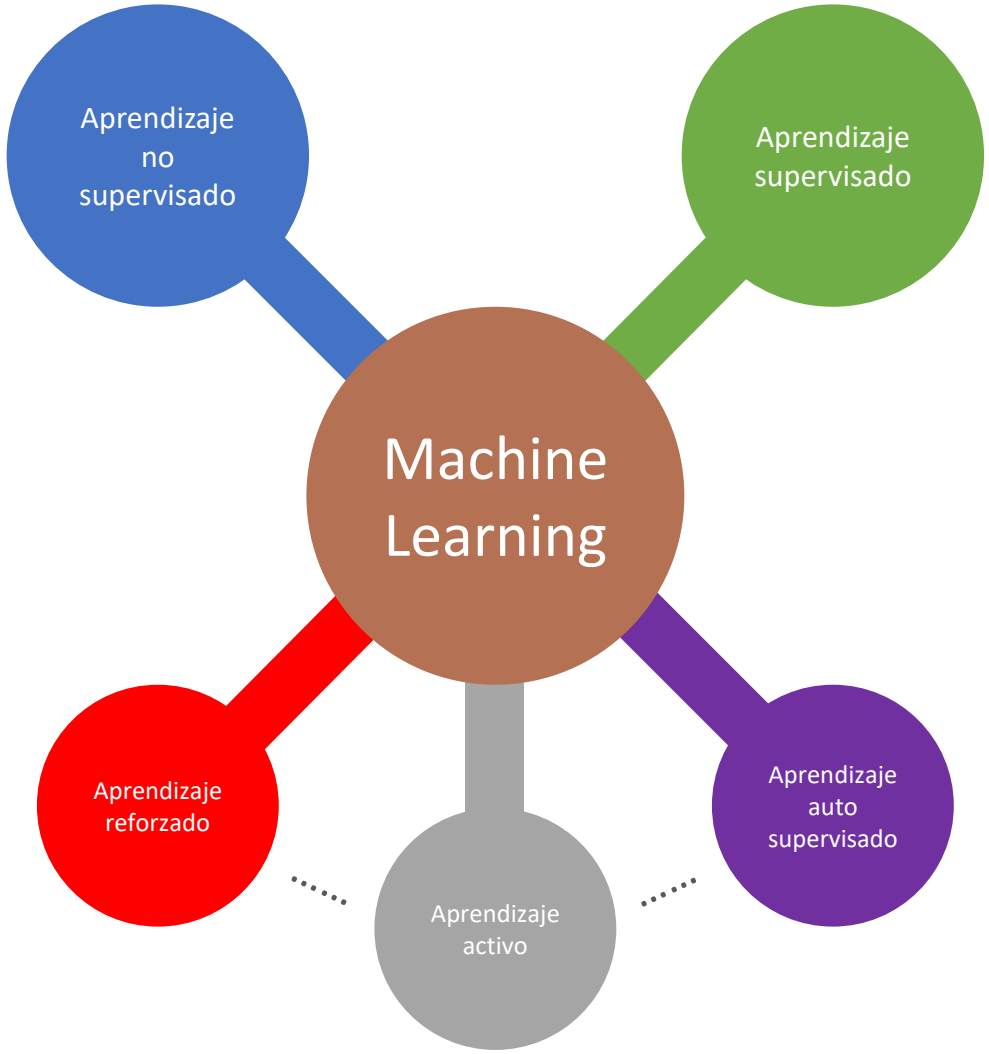
Aprendizaje no supervisado
Aprendizaje supervisado
Machine Learning
Aprendizaje reforzado
Aprendizaje activo
Aprendizaje auto supervisado

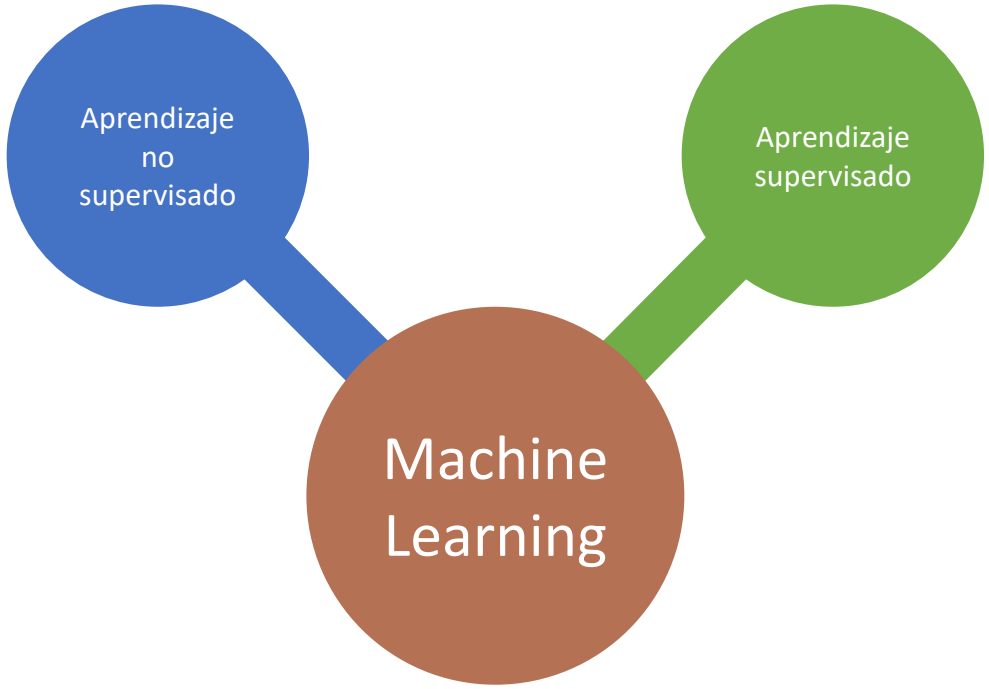
Aprendizaje no supervisado
Aprendizaje supervisado
Machine Learning

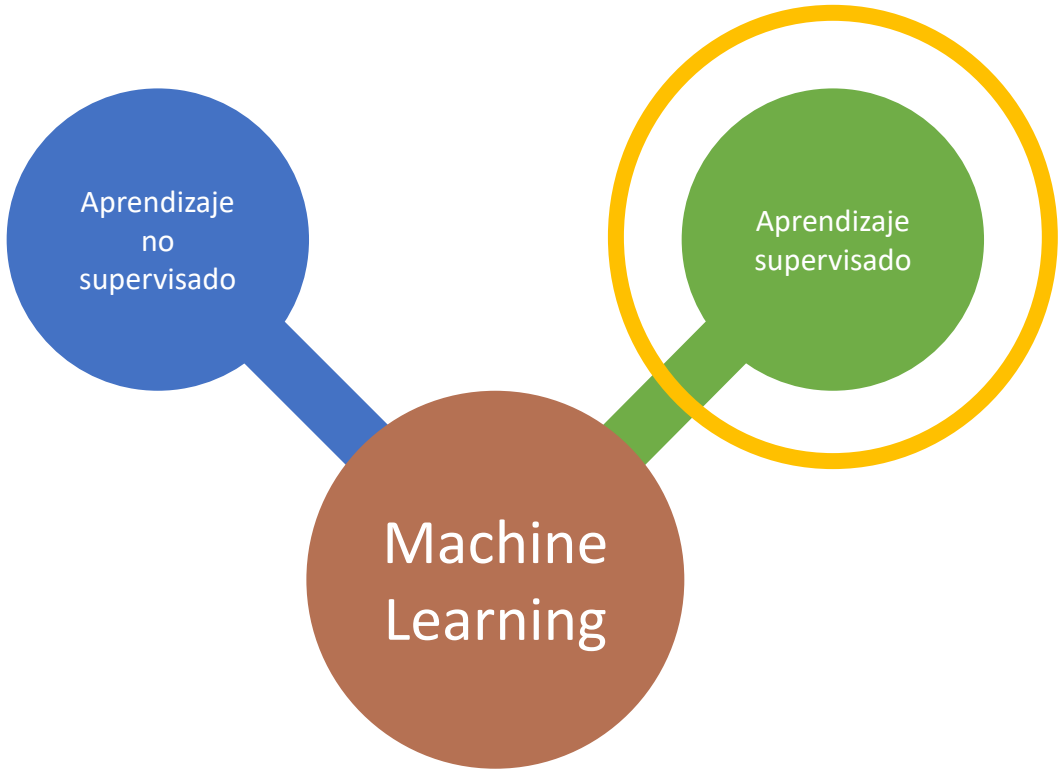
Aprendizaje
no
supervisado
Aprendizaje
supervisado
Machine
Learning

Cat

Dog

¿ ?

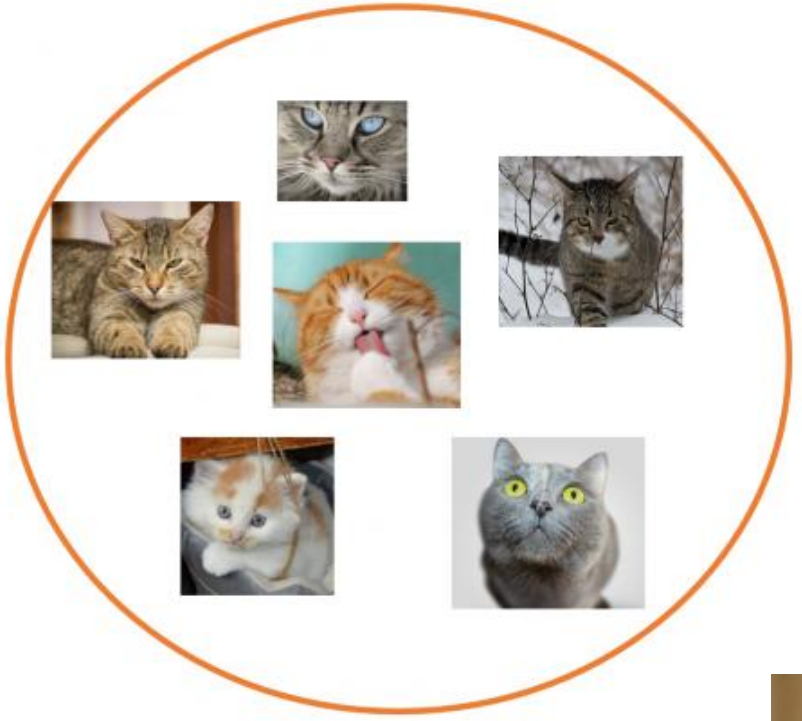

Cat

Dog

¿ ?

Como problema guía para lo que viene, estudiaremos la siguiente pregunta:

¿Cómo puedo estimar el ingreso anual promedio per cápita para los habitantes de una ciudad?

Como insumo para el estudio, tenemos un archivo `.csv` con datos diversos para múltiples ciudades

Ciudad	Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
Metropolis	3.500.000	600	5.833	$45.000
Rivertown	1.200.000	150	8.000	$35.000
Coastline	2.800.000	300	9.333	$40.000
Highland	900.000	350	2.571	$30.000
Greenfield	600.000	400	1.500	$28.000
Sunnyside	750.000	500	1.500	$32.000
Frostville	300.000	200	1.500	$27.000
Eastbank	1.100.000	250	4.400	$36.000
Westwood	2.300.000	450	5.111	$42.000
Clearwater	500.000	180	2.777	$29.000
Ironforge	800.000	190	4.211	$40.000
Lakeview	950.000	220	4.318	$47.000
Cedarwood	410.000	300	1.367	$25.000
Newhaven	1.500.000	280	5.357	$70.000
Pinecrest	670.000	330	2.030	$33.000
Stonebridge	390.000	210	1.857	$11.000

(casi) Todas las técnicas de ML usan el mismo esquema de procesamiento

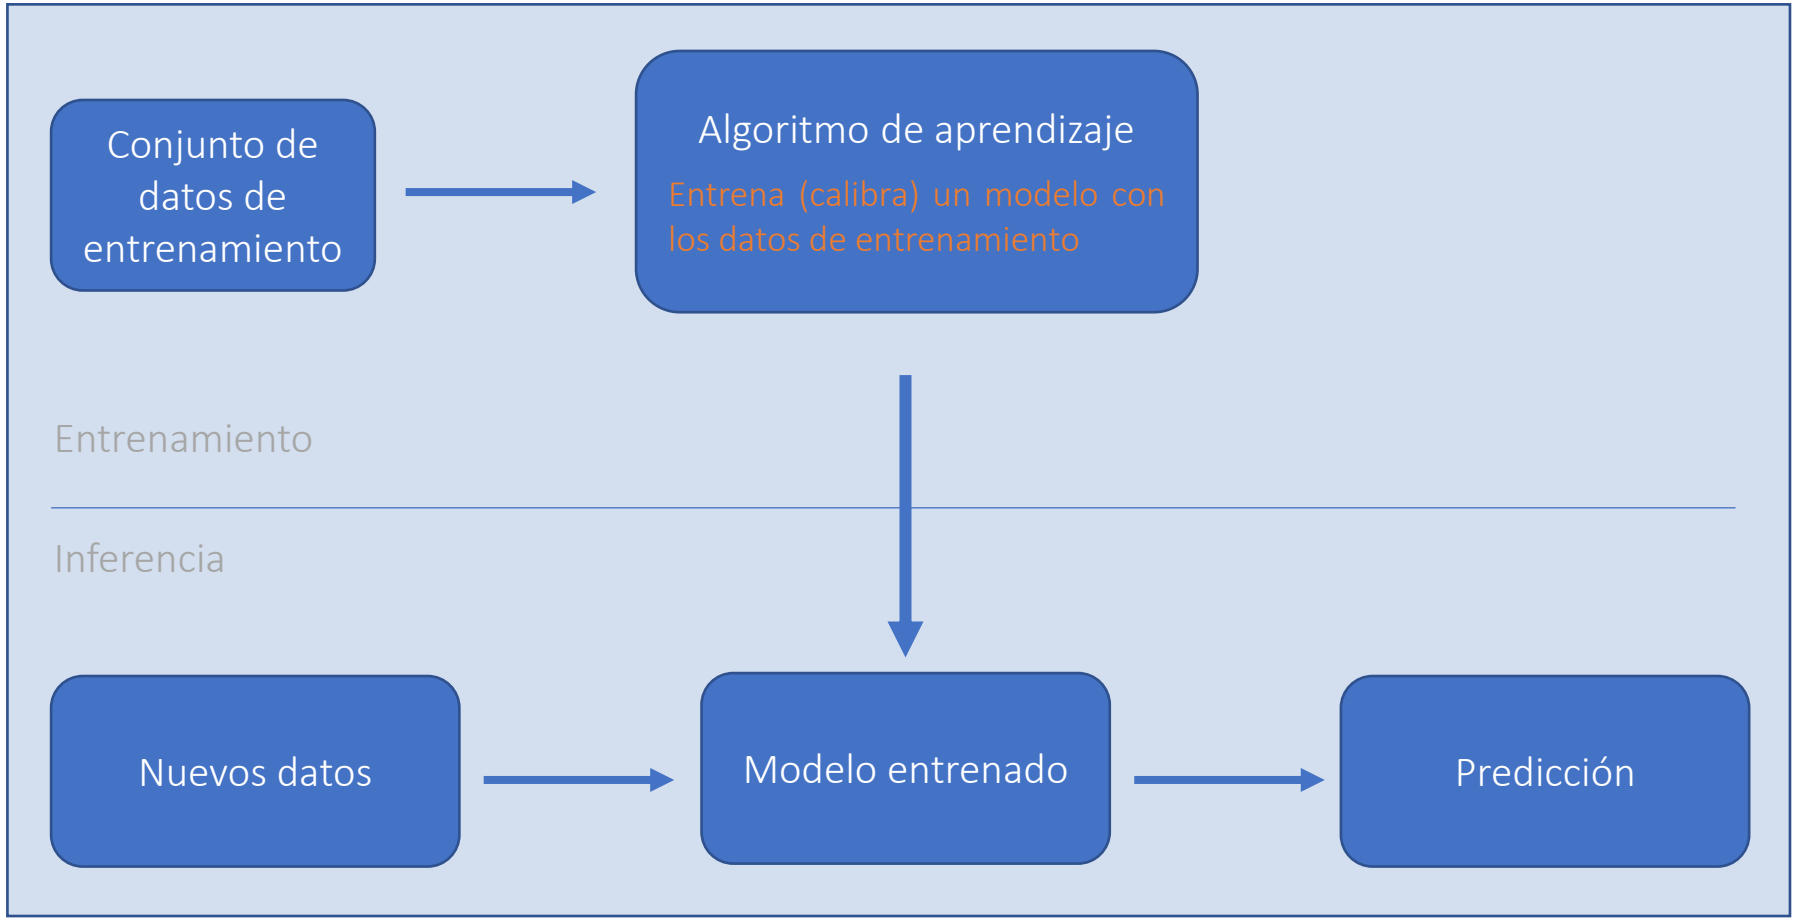

Técnicas de ML trabajan sobre datos multidimensionales

- Cada dato esta caracterizado por una serie de características = *features* = atributos = variables.
- Siempre buscaremos predecir algo a partir de estas características.
- Muchas veces, los datos poseen además una etiqueta = *label* = rótulo, que típicamente buscaremos predecir.

Próxima sesión veremos casos donde no hay etiqueta

Datos de Entrenamiento

Características			Etiqueta
Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
3.500.000	600	5.833	$45.000
1.200.000	150	8.000	$35.000
2.800.000	300	9.333	$40.000
900.000	350	2.571	$30.000
600.000	400	1.500	$28.000
750.000	500	1.500	$32.000
300.000	200	1.500	$27.000
1.100.000	250	4.400	$36.000

Técnicas de ML trabajan sobre datos multidimensionales

- Cada dato del conjunto de entrenamiento puede considerarse como un vector.
- La cantidad de características define la dimensionalidad del vector.
- El espacio donde viven los vectores se conoce como espacio de características.

Datos de Entrenamiento

Características			Etiqueta
Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
3.500.000	600	5.833	$45.000
1.200.000	150	8.000	$35.000
2.800.000	300	9.333	$40.000
900.000	350	2.571	$30.000
600.000	400	1.500	$28.000
750.000	500	1.500	$32.000
300.000	200	1.500	$27.000
1.100.000	250	4.400	$36.000

Cada dato puede verse como un vector/punto en el espacio de características

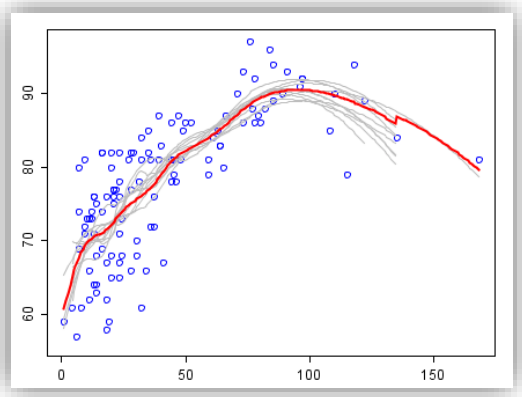

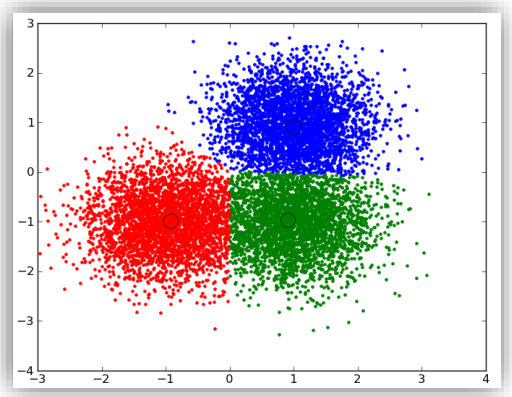

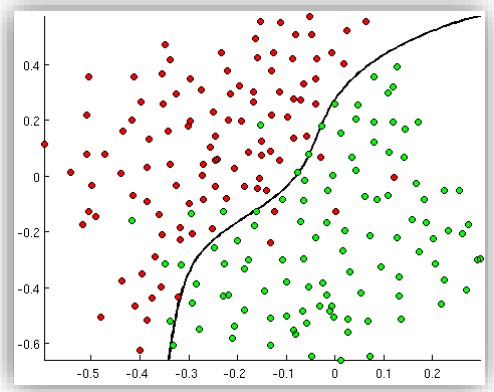

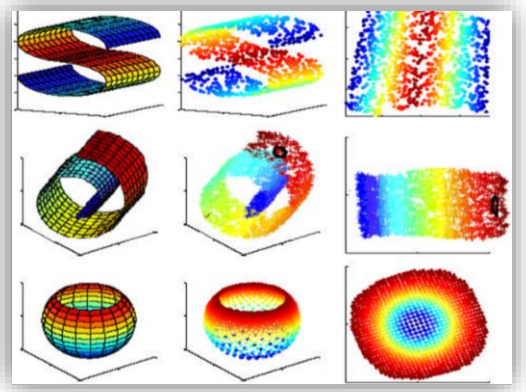

Esto hace que datos y tareas puedan interpretarse de manera más intuitiva desde un punto de vista geométrico

Teniendo las bases cubiertas, podemos revisar como usar *scikit-learn para resolver problemas predictivos*

Scikit-learn será nuestra herramienta principal para este capítulo

- scikit-learn es el módulo para ML más conocido y utilizado en Python.
- Su principal atractivo es una interfaz limpia, uniforme y simple, que facilita la exploración y permite la integración con otros paquetes, como Pandas.
- Posee además de una completa documentación en línea (https://scikit-learn.org/).

Esquema de datos de scikit-learn es similar a Pandas

- Datos son representados por una matriz de *características* y, si la tarea a resolver es supervisada, un vector objetivo de etiquetas.

- Las características de los ejemplos se almacenan en una matriz de característcas (X), de tamaño [n_samples, n_features] (esta matriz típicamente será un DataFrame, pero puede ser de otro tipo).

- En el caso supervisado, el vector objetivo (y) contiene la etiqueta para cada ejemplo y tiene tamaño [n_samples, 1] (este vector típicamente será un Series, pero puede ser de otro tipo).

- Y eso es todo…

Esquema de datos es similar a Pandas

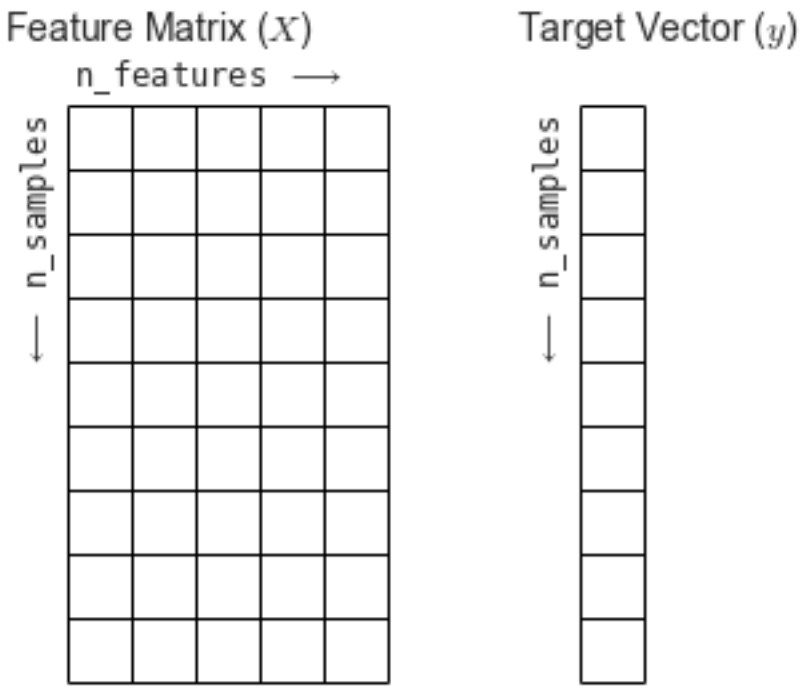

Población	Superficie (km²)	Densidad poblacional por km²	Ingreso anual promedio per cápita en dólares
3.500.000	600	5.833	$45.000
1.200.000	150	8.000	$35.000
2.800.000	300	9.333	$40.000
900.000	350	2.571	$30.000
600.000	400	1.500	$28.000
750.000	500	1.500	$32.000
300.000	200	1.500	$27.000
1.100.000	250	4.400	$36.000

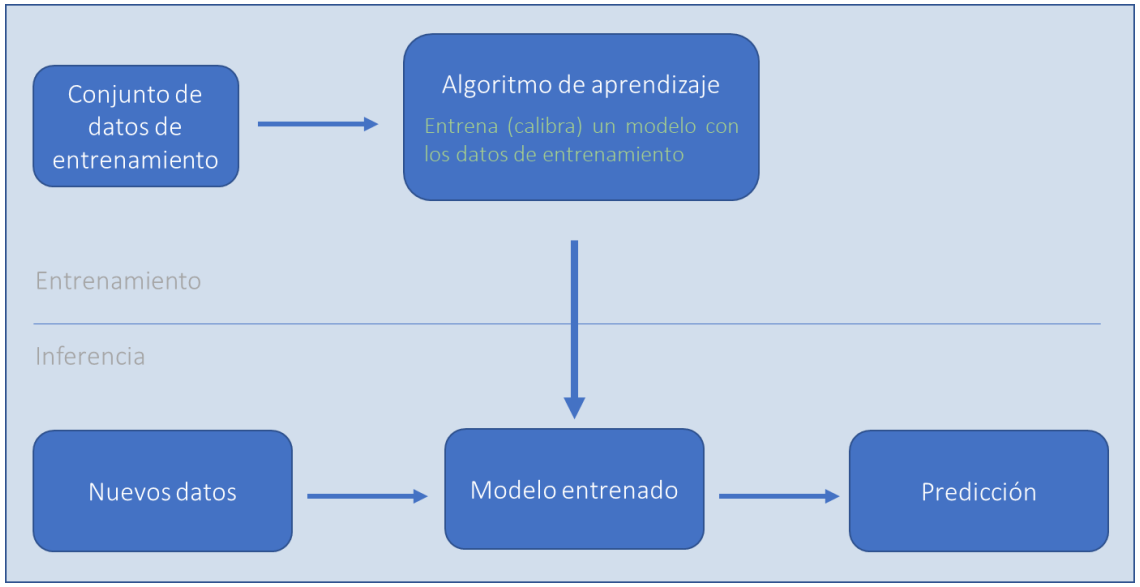

En base a los datos y al funcionamiento de ML, ¿cómo podríamos plantear el problema de predicción usando scikit-learn?

Uso de los modelos es simple y directo

En general, un caso de uso típico en scikit-learn es como el siguiente:

1. Obtener o generar matriz X y vector y → Preparar los datos (ver la materia antes de tirarse directo a los ejercicios)
2. Elegir modelos adecuados, importando la clase correspondiente desde *sklearn.*
3. Entrenar los modelos llamando al método fit(X, y).
4. Seleccionar el modelo final mediante validación (ver la materia antes de tirarse directo a los ejercicios).
5. Aplicar el modelo entrenado en nuevos datos, usando el método predict().

Preparación de los datos tiene un foco distinto

- El objetivo es que los datos de entrenamiento sean lo más representativos posibles del problema a resolver.
- Así, queremos incorporar la menor cantidad posible de supuestos sobre ellos, de modo que el modelo aprenda de los datos y no de nosotros.
- ¿Qué implica esto en la práctica? Que son más importantes las cosas que están que las que no lo están o que presentan fallas.
- Esto último no implica que vamos a descartar los datos faltantes o outliers, sino que pueden ser corregidos posteriormente mediante modelos entrenados sobre los datos “correctos”.
- Para asegurar esto, es necesario seguir un protocolo bien definido que considera etapas de codificación, división de conjuntos y transformación, entre otros (nuevamente, ver la materia antes de tirarse directo a los ejercicios).

¿Cómo puedo entonces elegir el modelo final?

- Lo primero que necesitamos es una manera de medir el rendimiento de un modelo, para lo que debemos definir dos cosas: una métrica de rendimiento y un conjunto de prueba.
- La métrica de rendimiento estará dada generalmente por la tarea a resolver (scikit-learn ofrece muchas en el módulo `sklearn.metrics`).
- El conjunto de pruebas debe venir de la misma distribución de datos que el conjunto de entrenamiento (nuevamente scikit-learn nos facilita el trabajo con el método `train_test_split`).
- Más que antes incluso, es fundamental revisar la material para hacer esto correctamente.

	Población	Superficie (km^2)	Densidad poblacional por km^2	Ingreso anual promedio per cápita en dólares
Entrenamiento	3.500.000	600	5.833	$45.000
	1.200.000	150	8.000	$35.000
	2.800.000	300	9.333	$40.000
	900.000	350	2.571	$30.000
	600.000	400	1.500	$28.000
	750.000	500	1.500	$32.000
	300.000	200	1.500	$27.000
	1.100.000	250	4.400	$36.000
	2.300.000	450	5.111	$42.000
	500.000	180	2.777	$29.000
Prueba/Test	800.000	190	4.211	?
	950.000	220	4.318	
	410.000	300	1.367	
	1.500.000	280	5.357	
	670.000	330	2.030	
	390.000	210	1.857	

En resumen…

- ML se centra en algoritmos/modelos que aprenden de los datos para resolver una tarea
- scikit-learn permite hacer ML en Python de manera práctica y rápida
- (casi) Todas las técnicas de ML funcionan de la misma manera
- Qué técnica usar dependerá de la tarea y los datos disponibles, pero siempre se debe decidir en base a métricas de rendimiento
- Todo esto y mucho más en los cursos IIC2613 – Inteligencia Artificial, ICT3115 – Sistemas Urbanos Inteligentes e IIC3697 – Aprendizaje Profundo.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

IIC2115 - Programación como herramienta para la ingeniería

Modelos Predictivos basados en Machine Learning

Profesor: Hans Löbel