Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2115 - Programación como Herramienta para la Ingeniería

Extracción de datos

Profesores: Camila Vera / Hans Löbel

Esta parte del capítulo del curso apunta a dos problemas muy comunes en la práctica

- Muchas veces los datos no están disponibles en archivos o fuentes fácilmente accesibles.
- Luego, una vez que los tenemos disponibles y preparados, su visualización efectiva y atractiva demanda mucho tiempo de preparación.
- Para enfrentar ambas situaciones, en este capítulo cubriremos:
  - Descarga de información desde la Web, utilizando diversas técnicas.
  - Visualización de datos a través de dashboards rápidamente desplegables en Python.



Web Scraping

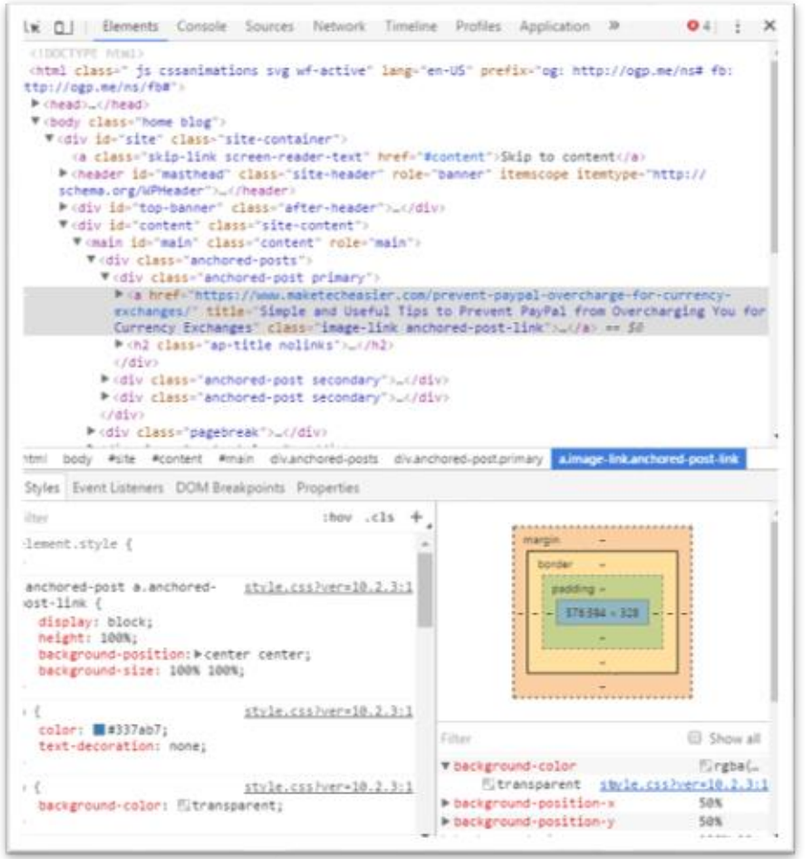
Es el esquema más común para extraer información desde la web de manera automática

- **Definición**: proceso de extracción de datos de páginas web de manera automatizada.
- **Objetivo**: recopilar información que no está disponible de manera directamente para una máquina.
- **Aplicaciones**: análisis de mercado, recopilación de datos para proyectos de machine learning, monitoreo de precios, entre otros.



Pasos Simples para Web Scraping

1. Seleccionar el sitio web: identificar la página que tiene los datos necesarios.
2. Buscar los datos: inspeccionar el código HTML para localizar los elementos que contienen los datos deseados.
3. Extraer los datos: usar un lenguaje de programación como Python para extraer los datos.
4. Guardar los datos: almacenar la información en un formato útil, como CSV o JSON.
5. Procesar y consultar los datos: utilizar herramientas como Pandas para limpiar, transformar y analizar la información extraída.



Web Scraping en Python

- **BeautifulSoup** (BS4): Para analizar HTML y extraer información específica.

```python
import requests
from bs4 import BeautifulSoup
import pandas as pd

url = 'https://ejemplo.com'
response = requests.get(url)
soup = BeautifulSoup(response.text, 'html.parser')

# Extraer datos
titles = [title.get_text() for title in soup.find_all('h2')]
# Organizar y guadrar con pandas
df = pd.DataFrame(titles, columns=['Title'])
df.to_csv('output.csv', index=False)
```

- **Pandas**: Para organizar, limpiar, analizar y también extraer datos de tablas HTML.

```python
# Extraer datos con pandas
import pandas as pd

url = 'https://ejemplo.com'
tables = pd.read_html(url)  # Extrae todas las tablas de la página
df = tables[0]  # Selecciona la primera tabla extraída
```

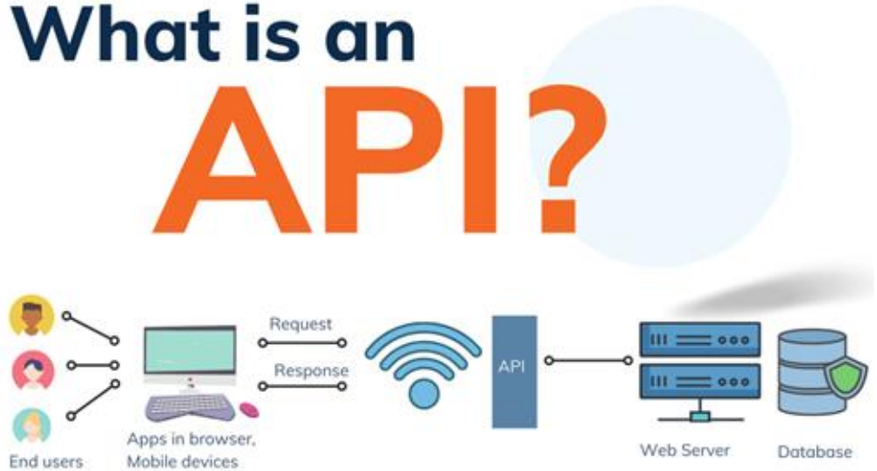
Consideraciones Importantes

- *Rate Limiting*: no sobrecargar los servidores, usar pausas entre *requests*.
- Manejo de Errores: usar manejo de excepciones para evitar que el script falle.
- Tiempo de Ejecución por Request: usar `time.sleep()` para retrasar solicitudes y evitar bloqueos.
- Rotación de IPs y *User Agents*: técnica para cambiar la IP y el agente de usuario en cada solicitud y evitar bloqueos por parte del sitio.

API

La descarga de información a través de API ofrece una alternativa más práctica y ordenada, pero no siempre está disponible o es pagada

- Definición: conjunto de reglas que permite que dos sistemas se comuniquen entre sí de forma estructurada.
- Objetivo: facilitar el acceso a datos o funcionalidades de un sistema sin necesidad de interactuar directamente con su interfaz interna.
- Aplicaciones: integración de servicios, automatización de procesos, acceso a datos en tiempo real (como clima, mapas, redes sociales), entre otros.



Ventajas de usar APIs

- Facilitan la integración entre aplicaciones.
- Permiten acceso a datos actualizados en tiempo real.
- Promueven la reutilización de servicios.
- Mejoran la escalabilidad de sistemas.



Componentes básicos de una request a una API

- URL: Dirección del endpoint al que se hace la solicitud (ej: https://api.openweathermap.org/data/2.5/weather).
- API Key: Clave que identifica al usuario y otorga acceso autorizado al servicio.
- Headers: Información adicional que acompaña la solicitud (ej: tipo de contenido, autorización).
- Parámetros: Datos enviados en la URL o el cuerpo para especificar la consulta (ej: ciudad, unidades, idioma).
- Respuesta (JSON): La mayoría de las APIs modernas devuelven datos en formato JSON, fácil de leer y procesar.

```
1 API_KEY = os.getenv("API_KEY")
2 ciudad = "Santiago"
3 url = f"http://api.openweathermap.org/data/2.5/weather?q={ciudad}&appid={API_KEY}"
4
5 respuesta = requests.get(url)
6 datos = respuesta.json()
```

¿Cómo se construye la URL de una request a una API?

- Dominio base: la dirección del servidor de la API
    - Ej: https://api.openweathermap.org
- Endpoint: ruta específica para el recurso deseado
    - Ej: /data/2.5/weather
- Parámetros de consulta: valores clave para personalizar la respuesta
    - Ej: ?q=Santiago&units=metric&appid=TU_API_KEY

```
1 API_KEY = os.getenv("API_KEY")
2 ciudad = "Santiago"
3 url = f"http://api.openweathermap.org/data/2.5/weather?q={ciudad}&appid={API_KEY}"
4
5 respuesta = requests.get(url)
6 datos = respuesta.json()
```

Diferencias entre Web Scraping y API

	Web Scraping	API
Fuente de datos	HTML de páginas web	Respuesta estructurada (JSON/XML)
Robustez	Frágil ante cambios en el sitio	Más estable y documentada
Velocidad	Típicamente lenta	Muy rápida
Eficiencia de uso	Requiere procesar el HTML	Acceso directo a la información

¿Cómo son los ejercicios en este capítulo?

- El flujo comienza típicamente con la identificación de o los sitios web o APIs donde se encuentra la información requerida.
- Si se usa web scraping, se deberá explorar los sitios web y luego construir un algoritmo que extraiga la información desde el HTML descargado.
- Si se usa API, se deberá conseguir el acceso a esta (ojo con el manejo de la API key) y configurar adecuadamente los llamados.
- Finalmente, se deberá desarrollar la visualización con Dash, apuntando a la efectividad en la comunicación de la información, combinado con una representación atractiva. (próxima sesión)







Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2115 - Programación como Herramienta para la Ingeniería

Extracción de datos

Profesores: Camila Vera / Hans Löbel