Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

IIC2115 - Programación como Herramienta para la Ingeniería

Bases de datos relacionales y Web Scraping

Profesor: Pablo Seisdedos

¿Qué es una base de datos?

1. Corresponde a un conjunto de datos de un mismo contexto y almacenados bajo cierta lógica/estructura e indexados para su posterior uso eficiente.

2. En el caso de una base relacional, es una colección de una o más relaciones, donde cada relación es una tabla con filas y columnas.

RELATIONAL DATABASE

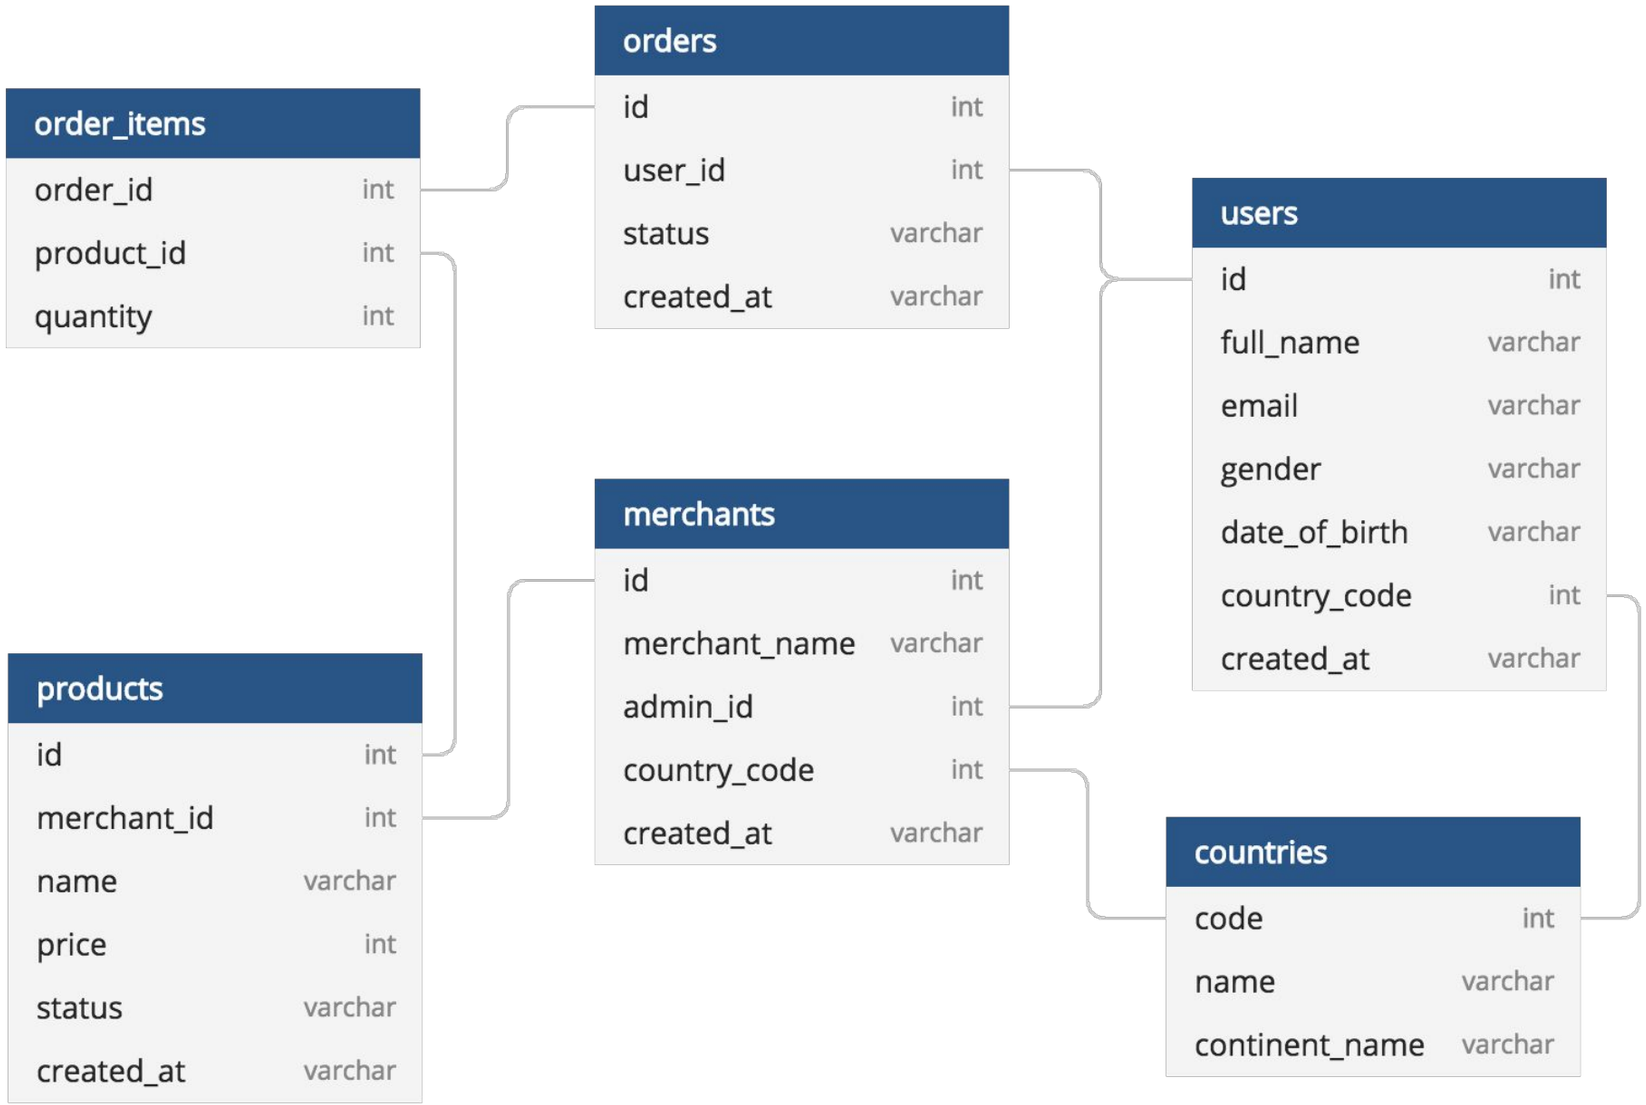
order_items
order_id int
product_id int
quantity int
orders
id int
user_id int
status varchar
created_at varchar
users
id int
full_name varchar
email varchar
gender varchar
date_of_birth varchar
country_code int
created_at varchar
merchants
id int
merchant_name varchar
admin_id int
country_code int
created_at varchar
products
id int
merchant_id int
name varchar
price int
status varchar
created_at varchar
countries
code int
name varchar
continent_name varchar

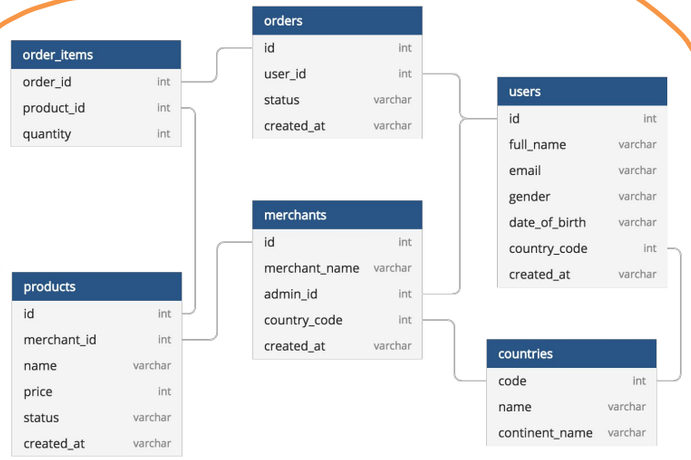

Esquema (Schema)

Base de datos (Database)

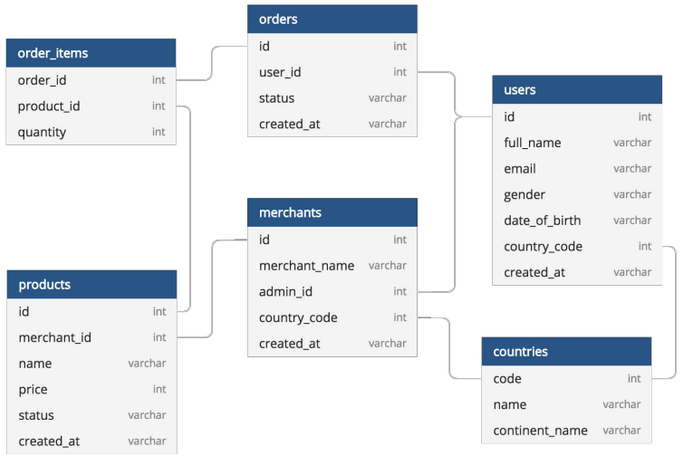

Tabla (Table)

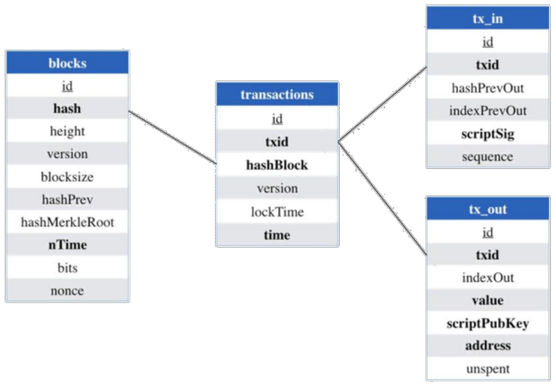

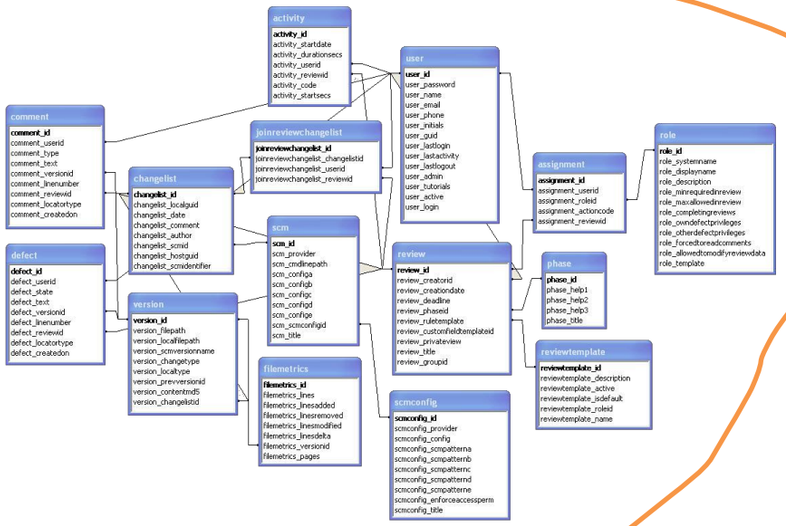

Tabla

Columna: guarda un tipo específico de datos

CHAR(N)
VARCHAR(N)
INTEGER
REAL
…

Fila: corresponde a un registro o instancia

Emp No	Name	Age	Department	Salary
001	Alex S	26	Store	5000
002	Golith K	32	Marketing	5600
003	Rabin R	31	Marketing	5600
004	Jons	26	Security	5100

Empleados (Emp No: STRING, Name: STRING, Age: INTEGER, Department: STRING, Salary: REAL)

Llaves primarias y secundarias (primary keys & foreign keys)

Emp No	Name	Age	Department_id	Salary
001	Alex S	26	1	$000
002	Golith K	32	2	$600
003	Rabin R	31	2	$600
004	Jons	26	3	$100

P
K

FK

Id	Department
1	Store
2	Marketing
3	Security

P
K

No hay
FK

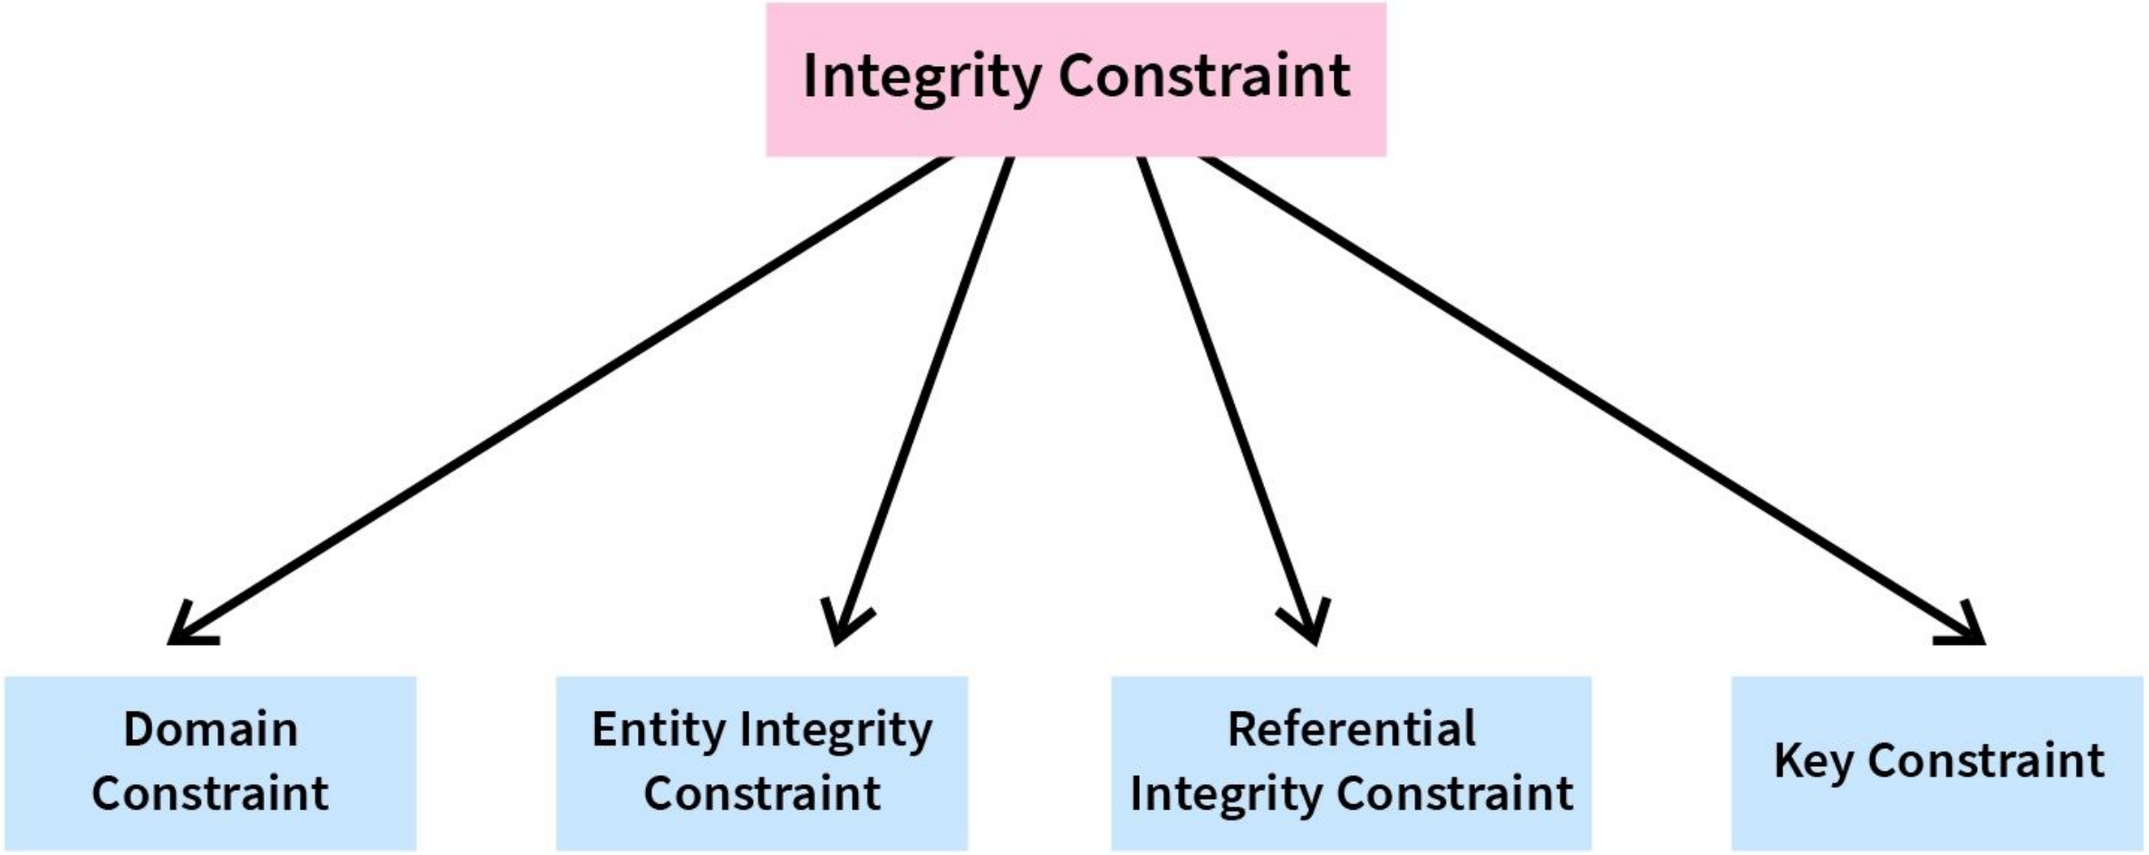
Integrity Constraint
Domain Constraint
Entity Integrity Constraint
Referential Integrity Constraint
Key Constraint

Structured Query Language (SQL)

- Lenguaje de definición de datos (DDL)
  - Creación
  - Inserción
  - Eliminación
  - Modificación de definiciones de tablas.

  *Las restricciones de integridad se pueden definir en tablas, ya sea cuando se crea la tabla o posteriormente.

- Lenguaje de manipulación de datos (DML)
  - Consultas

- En este curso utilizaremos SQLite, una versión reducida de SQL, que tiene algunas diferencias menores en sus sintaxis.

Creación

CREATE TABLE [**IF NOT EXISTS**] table_name (column_1 data_type, column_2 data_type, …)

Emp No	Name	Age	Department	Salary
001	Alex S	26	Store	5000
002	Golith K	32	Marketing	5600
003	Rabin R	31	Marketing	5600
004	Jons	26	Security	5100

CREATE TABLE Empleados (Emp_No **CHAR(3)**, Name **VARCHAR(20)**, Age **INTEGER**, Department **VARCHAR(10)**, Salary **INTEGER**)

Creación (en SQLite)

CREATE TABLE [**IF NOT EXISTS**] table_name (column_1 data_type, column_2 data_type, …)

Emp No	Name	Age	Department	Salary
001	Alex S	26	Store	5000
002	Golith K	32	Marketing	5600
003	Rabin R	31	Marketing	5600
004	Jons	26	Security	5100

CREATE TABLE Empleados (Emp_No **TEXT**, Name **TEXT**, Age **INTEGER**, Department **TEXT**, Salary **INTEGER**)

Inserción

INSERT INTO table_name (column1,column2 ,..) **VALUES**(value1, value2 ,...)

Emp No	Name	Age	Department	Salary
001	Alex S	26	Store	5000
002	Golith K	32	Marketing	5600
003	Rabin R	31	Marketing	5600

INSERT INTO Empleados (Emp_No, Name, Age**,** Department, Salary) **VALUES** (‘004’, ‘Jons’, 26, ‘Security’, 5100)

Modificación

UPDATE table_name **SET** column_1 = new_value_1, column_2 = new_value_2
WHERE search_condition

Emp No	Name	Age	Department	Salary
001	Alex S	26	Store	5000
002	Golith K	32	Marketing	5600
003	Rabin R	31	Marketing	5600
004	Jons	26	Marketing	5100

UPDATE Empleados E **SET** E.Department = ‘Marketing’ **WHERE** E.Emp_No = ‘004’

Eliminación

DELETE FROM table_name **WHERE** search_condition;

Emp No	Name	Age	Department	Salary
001	Alex S	26	Store	5000
002	Golith K	32	Marketing	5600
003	Rabin R	31	Marketing	5600

DELETE FROM Empleados E **WHERE** E.Emp_No = ‘004’

Creación de tablas con *Primary Key* y *Foreign Key*

Emp No	Name	Age	Department_id	Salary
001	Alex S	26	1	5000
002	Golith K	32	2	5600
003	Rabin R	31	2	5600
004	Jons	26	3	5100

Id	Department
1	Store
2	Marketing
3	Security

CREATE TABLE Departments (Id **INTEGER** **PRIMARY KEY**, Department **VARCHAR(20)**)

CREATE TABLE Empleados (Emp_No **TEXT** **PRIMARY KEY**, Name **TEXT**, Age **INTEGER**, Department_id **INTEGER**, Salary **INTEGER**, **FOREIGN KEY** (Department_id) REFERENCES Departments)

Uso en Python: DDL

```
import sqlite3

connection = sqlite3.connect(‘ejemplo.db’)
cursor = connection.cursor()

sqlStatement = ‘CREATE TABLE Empleados (Emp_No TEXT, Name TEXT, Age INTEGER, Department TEXT, Salary INTEGER)’
cursor.execute(sqlStatement)

Sql2 = ‘INSERT INTO Empleados (Emp_No, Name, Age, Department, Salary) VALUES (‘004’, ‘Jons’, 26, ‘Security’, 5100)’

cursor.execute(Sql2)

connection.commit()
connection.close()
```

Manejo de errores

Al desarrollar este capítulo, se encontrarán dos tipos de errores:

- Errores de Python (de los que ya están familiarizados)
- Errores de la sintaxis de la base de datos (SQL)

CONSEJO: Pueden testear sus consultas directamente en la base de datos (p.ej., con DB Browser for SQLite) y luego utilizarla en Python

¿Qué es Web Scraping?

- Definición: Proceso de extracción de datos de páginas web de manera automatizada.
- Objetivo: Recopilar información que no está disponible directamente a través de APIs o bases de datos.
- Aplicaciones: Análisis de mercado, recopilación de datos para proyectos de machine learning, monitoreo de precios, entre otros.

Pasos Simples para Web Scraping

- Seleccionar el sitio web: Identificar la página que tiene los datos necesarios.
- Buscar los datos: Inspeccionar el HTML para localizar los elementos que contienen los datos deseados.
- Extraer los datos: Usar un lenguaje de programación como Python para extraer los datos.
- Guardar los datos: Almacenar la información en un formato útil, como CSV o JSON.
- Procesar y consultar los datos: Utilizar herramientas como Pandas para limpiar, transformar y analizar la información extraída.

Web Scraping en Python

- BeautifulSoup (BS4): Para analizar HTML y extraer información específica.
- Pandas: Para organizar, limpiar, analizar y también extraer datos de tablas HTML.

```python
# Extraer datos con pandas
import pandas as pd

url = 'https://ejemplo.com'
tables = pd.read_html(url)  # Extrae todas las tablas de la página
df = tables[0]  # Selecciona la primera tabla extraída
```

```python
import requests
from bs4 import BeautifulSoup
import pandas as pd

url = 'https://ejemplo.com'
response = requests.get(url)
soup = BeautifulSoup(response.text, 'html.parser')

# Extraer datos
titles = [title.get_text() for title in soup.find_all('h2')]
# Organizar y guadrar con pandas
df = pd.DataFrame(titles, columns=['Title'])
df.to_csv('output.csv', index=False)
```

Consideraciones Importantes

- Rate Limiting: No sobrecargar los servidores; usar pausas entre requests.
- Manejo de Errores: Usar manejo de excepciones para evitar que el script falle.
- Tiempo de Ejecución por Request: Usar time.sleep() para retrasar solicitudes y evitar bloqueos.
- Rotación de IPs y User Agents: Técnica para cambiar la IP y el agente de usuario en cada solicitud y evitar bloqueos por parte del sitio.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

IIC2115 - Programación como Herramienta para la Ingeniería

Bases de datos relacionales y Web Scraping

Profesor: Pablo Seisdedos